TRƯỜNG ĐẠI HỌC KINH TẾ - KỸ THUẬT CÔNG NGHIỆP HÀ NỘI

KHOA KHOA HỌC ỨNG DỤNG

BÁO CÁO MÔN
ĐỒ ÁN 2

ĐỀ TÀI

TRIỂN KHAI MÔ HÌNH HỌC MÁY CHO PHÂN LOẠI VÀ PHÂN CỤM DỮ LIỆU NHIỆT ĐỘ TRONG IOT

GV hướng dẫn: LÊ HẰNG ANH

Nhóm sinh viên thực hiện:

Họ và tên	*MSSV*	*Lớp học*
Bùi Mạnh Dương	23174600078	DHKL17A2HN
Đào Thị Hà Vy	23174600093	DHKL17A2HN
Trương Thị Thu Hoài	23174600054	DHKL17A2HN
Hồ Như Minh	23174600099	DHKL17A2HN

Hà Nội, 2026

Mục lục

1 Giới thiệu **3**
- 1.1 Bối cảnh bài toán . . . 3
- 1.2 Mục tiêu nghiên cứu . . . 3
- 1.3 Ý nghĩa thực tiễn . . . 4
- 1.4 Tổng quan phương pháp . . . 4

2 Thu thập và xây dựng dữ liệu **5**
- 2.1 Thu thập dữ liệu . . . 5
  - 2.1.1 Nguồn dữ liệu . . . 5
  - 2.1.2 Phương pháp thu thập . . . 5
- 2.2 Mô tả dữ liệu thô . . . 5
- 2.3 Tiền xử lý dữ liệu ban đầu . . . 6
- 2.4 Xây dựng đặc trưng . . . 7
  - 2.4.1 Cho bài toán phân cụm . . . 7
  - 2.4.2 Cho bài toán phân loại . . . 8

3 Khám phá dữ liệu (EDA) **10**
- 3.1 Thống kê mô tả . . . 10
- 3.2 Kiểm tra dữ liệu thiếu . . . 10
- 3.3 Phân phối dữ liệu . . . 11
- 3.4 Nhận xét . . . 12

4 Tiền xử lý dữ liệu cho mô hình **13**
- 4.1 Làm sạch dữ liệu . . . 13
- 4.2 Lựa chọn đặc trưng . . . 15
- 4.3 Chuẩn hóa dữ liệu . . . 16
- 4.4 Chia tập dữ liệu . . . 17

5 Áp dụng mô hình học máy **18**
- 5.1 Tổng quan phương pháp . . . 18
  - 5.1.1 Phân loại bài toán . . . 19
  - 5.1.2 Quy trình huấn luyện . . . 20
- 5.2 Bài toán 1: Phân cụm thành phố . . . 21
  - 5.2.1 Thuật toán K-Means . . . 21
  - 5.2.2 Triển khai K-Means từ đầu . . . 22
  - 5.2.3 Sử dụng thư viện (Sklearn) . . . 25
  - 5.2.4 Đánh giá mô hình . . . 26
  - 5.2.5 Trực quan hóa kết quả . . . 27

5.2.6 Phân tích các cụm . . . 27
5.2.7 So sánh mô hình (From Scratch vs Thư viện) . . . 29
5.3 Bài toán 2: Dự đoán trạng thái nhiệt độ . . . 30
5.3.1 Mô hình Logistic Regression . . . 31
5.3.2 Triển khai Softmax từ đầu . . . 32
5.3.3 Sử dụng thư viện . . . 36
5.3.4 Phân tích đặc trưng . . . 38
5.3.5 Phân tích đặc trưng (Feature Analysis) . . . 39
5.3.6 Phân tích hội tụ . . . 41
5.3.7 So sánh code tay và thư viện . . . 42
5.3.8 So sánh tổng quan các mô hình . . . 42

6 Kết quả và thảo luận **44**
6.1 Kết quả phân cụm . . . 44
6.2 Kết quả phân loại . . . 44
6.3 Kết luận . . . 44
6.4 Ưu điểm . . . 45
6.5 Hạn chế . . . 45

7 Kết luận **47**
7.1 Tóm tắt . . . 47
7.2 Ý nghĩa . . . 47
7.3 Hướng phát triển . . . 48
7.3.1 Mở rộng dữ liệu . . . 48
7.3.2 Cải tiến mô hình . . . 48
7.3.3 Tổng kết hướng phát triển . . . 49

8 Tài liệu tham khảo **50**

Chương 1

Giới thiệu

1.1 Bối cảnh bài toán

Trong bối cảnh biến đổi khí hậu toàn cầu ngày càng diễn biến phức tạp, nhiệt độ môi trường đang trở thành một trong những yếu tố quan trọng ảnh hưởng trực tiếp đến đời sống con người, hoạt động sản xuất, nông nghiệp, giao thông và quy hoạch đô thị. Việc theo dõi, phân tích và dự đoán trạng thái nhiệt độ không chỉ giúp nâng cao khả năng ứng phó với thời tiết cực đoan mà còn hỗ trợ các cơ quan quản lý và doanh nghiệp trong việc đưa ra quyết định phù hợp.

Hiện nay, lượng dữ liệu khí tượng được thu thập ngày càng lớn từ các trạm quan trắc, cảm biến môi trường và hệ thống vệ tinh. Tuy nhiên, để khai thác hiệu quả nguồn dữ liệu này, cần áp dụng các phương pháp phân tích dữ liệu và học máy nhằm tìm ra quy luật tiềm ẩn cũng như xây dựng các mô hình dự đoán chính xác.

Xuất phát từ thực tiễn đó, nhóm 14 thực hiện đề tài "Phân cụm thành phố theo đặc trưng nhiệt độ và xây dựng mô hình dự đoán trạng thái nhiệt độ" nhằm ứng dụng các kỹ thuật Machine Learning vào bài toán khí tượng thực tế.

1.2 Mục tiêu nghiên cứu

Đề tài tập trung giải quyết hai bài toán chính:

Bài toán 1: Phân cụm thành phố theo đặc trưng nhiệt độ

Trong bài toán này, dữ liệu nhiệt độ của các thành phố được phân tích nhằm nhóm các thành phố có đặc điểm nhiệt độ tương đồng vào cùng một cụm. Thuật toán K-Means được sử dụng để thực hiện phân cụm dựa trên mức độ giống nhau giữa các dữ liệu.

Số cụm tối ưu được xác định thông qua Elbow Method và Silhouette Score để đảm bảo kết quả phân cụm hợp lý và hiệu quả. Đồng thời, bài toán cũng so sánh giữa phiên bản K-Means tự xây dựng từ đầu và phiên bản sử dụng thư viện Scikit-learn để đánh giá sự khác biệt về kết quả và hiệu suất.

Cuối cùng, kết quả phân cụm được trực quan hóa nhằm giúp việc quan sát và phân tích trở nên rõ ràng và dễ hiểu hơn.

Bài toán 2: Xây dựng mô hình dự đoán trạng thái nhiệt độ

Trong bài toán này, các đặc trưng được tạo ra từ dữ liệu đầu vào nhằm phục vụ cho quá trình huấn luyện mô hình. Trên cơ sở đó, mô hình Logistic Regression được xây dựng để phân loại trạng thái nhiệt độ.

Bên cạnh đó, thuật toán Softmax Regression cũng được tự triển khai từ đầu để hiểu rõ cơ chế hoạt động của mô hình phân loại đa lớp. Các mô hình sau đó được huấn luyện và theo dõi quá trình hội tụ để đánh giá khả năng học của mô hình theo từng vòng lặp.

Tiếp theo, kết quả giữa mô hình tự cài đặt và mô hình sử dụng thư viện được so sánh nhằm đánh giá sự tương đồng về hiệu quả và độ chính xác. Cuối cùng, bài toán tiến hành phân tích mức độ ảnh hưởng của các đặc trưng đầu vào đối với kết quả dự đoán để xác định những yếu tố quan trọng nhất trong mô hình.

1.3 Ý nghĩa thực tiễn

Đề tài mang lại nhiều ý nghĩa cả về mặt ứng dụng thực tiễn và học thuật.

Về mặt ứng dụng, nghiên cứu giúp phân loại các khu vực có điều kiện nhiệt độ tương đồng, hỗ trợ cho quy hoạch đô thị và quản lý vùng. Đồng thời, kết quả dự đoán trạng thái nhiệt độ có thể phục vụ cảnh báo thời tiết, hỗ trợ ngành nông nghiệp trong việc lập kế hoạch sản xuất phù hợp với điều kiện khí hậu, cũng như giúp quản lý năng lượng hiệu quả hơn thông qua việc dự đoán nhu cầu sử dụng điện theo biến động nhiệt độ.

Về mặt học thuật, đề tài giúp hiểu rõ hơn nguyên lý hoạt động của các thuật toán Machine Learning thông qua việc tự xây dựng mô hình từ đầu. Việc so sánh giữa cách cài đặt thủ công và sử dụng thư viện chuẩn giúp làm rõ ưu điểm và hạn chế của từng phương pháp. Bên cạnh đó, quá trình thực hiện còn rèn luyện kỹ năng tiền xử lý dữ liệu, trực quan hóa và đánh giá mô hình, đồng thời tăng khả năng áp dụng lý thuyết vào các bài toán thực tế.

1.4 Tổng quan phương pháp

Đề tài được triển khai theo quy trình khoa học dữ liệu gồm các bước chính sau:

- Bước 1: Thu thập và tiền xử lý dữ liệu
- Bước 2: Phân tích khám phá dữ liệu (EDA)
- Bước 3: Giải quyết bài toán phân cụm
- Bước 4: Giải quyết bài toán phân loại
- Bước 5: So sánh và rút ra kết luận

Chương 2

Thu thập và xây dựng dữ liệu

2.1 Thu thập dữ liệu

2.1.1 Nguồn dữ liệu

Dữ liệu được khai thác từ hai nguồn thông tin chính trên website *Time and Date* (`https://www.timeanddate.com/`)

- **World Clock**: Cung cấp thông tin về thời gian địa phương và múi giờ của các thành phố trên toàn cầu.
- **Weather**: Cung cấp dữ liệu nhiệt độ thực tế tại thời điểm truy cập. Đây là nguồn dữ liệu thời gian thực có độ tin cậy cao, hỗ trợ việc theo dõi biến động khí hậu theo từng khung giờ tại nhiều quốc gia.

2.1.2 Phương pháp thu thập

Quá trình thu thập dữ liệu được thực hiện bằng phương pháp *Web Scraping* tự động thông qua thư viện *Selenium*. Quy trình cụ thể như sau:

- **Khởi tạo trình duyệt**: Sử dụng trình điều khiển Chrome tự động để truy cập trực tiếp vào các liên kết mục tiêu. Hệ thống được cấu hình để hoạt động ở chế độ tối ưu hóa, tránh các lỗi nhận diện tự động từ phía máy chủ.
- **Xử lý xác thực (Verification)**: Thiết lập cơ chế dừng chờ để người thực hiện báo cáo có thể tương tác thủ công nếu hệ thống yêu cầu xác minh bảo mật (Captcha/Verify), đảm bảo việc thu thập không bị chặn.
- **Trích xuất dữ liệu bảng**: Toàn bộ cấu trúc bảng (*Table*) chứa thông tin thành phố và nhiệt độ được bóc tách từ mã nguồn HTML. Dữ liệu sau đó được lưu trữ tạm thời dưới dạng các tệp trung gian kèm theo dấu thời gian (*Timestamp*) tại thời điểm thu thập để đảm bảo tính nhất quán.

2.2 Mô tả dữ liệu thô

Dữ liệu thô thu được từ quá trình thu thập có quy mô và cấu trúc như sau:

- **Kích thước bộ dữ liệu**: Tổng cộng 10.067 dòng và 5 cột thuộc tính.

- **Các trường thông tin**:
  - **city**: Tên thành phố nơi thu thập dữ liệu (Kiểu dữ liệu: String).
  - **local_time**: Thời gian địa phương tại thành phố đó, bao gồm thứ và giờ:phút (Kiểu dữ liệu: String).
  - **local_hour_24**: Giờ trong ngày định dạng 24h từ 0–23 (Kiểu dữ liệu: Integer).
  - **temperature**: Chỉ số nhiệt độ ghi nhận được tính theo đơn vị °C (Kiểu dữ liệu: Float).
  - **crawl_time**: Thời điểm hệ thống thực hiện lệnh thu thập dữ liệu theo định dạng YYYY-MM-DD HH:MM:SS (Kiểu dữ liệu: String).

Dữ liệu ở trạng thái thô có thể chứa các thành phần dư thừa như tên thứ (Sun, Mon) trong cột thời gian hoặc định dạng chuỗi cần được chuyển đổi.

Ví dụ:

City (Thô)	Time & Temp (Thô)	crawl_timestamp
Abidjan*	Mon 14:02 31°C	2026-04-13 21:00:00
Zürich	Mon 15:02 9°C	2026-04-13 21:00:00
Tiksi	Mon 22:02 -27°C	2026-04-13 21:00:00

2.3 Tiền xử lý dữ liệu ban đầu

Tại sao cần làm sạch dữ liệu?

Dữ liệu thô thu được từ web thường không đồng nhất và chứa nhiều ký tự rác (nhiễu). Việc tiền xử lý là bước then chốt nhằm:

- Chuẩn hóa định dạng: Chuyển đổi dữ liệu từ dạng văn bản thuần túy sang dạng số để có thể thực hiện các phép tính toán học.
- Đảm bảo tính chính xác: Loại bỏ các ký tự thừa hoặc các bản ghi lỗi phát sinh trong quá trình truyền tải dữ liệu.
- Tăng hiệu suất mô hình: Dữ liệu sạch giúp các thuật toán phân cụm hoặc phát hiện bất thường hoạt động hiệu quả hơn.

Các bước xử lý cụ thể

Dựa trên cấu trúc dữ liệu thu được, các thao tác tiền xử lý sau đã được thực hiện:

- Làm sạch văn bản: Loại bỏ hoàn toàn các ký tự đặc biệt (như dấu *) trong tên thành phố để định danh chính xác các địa điểm.
- Trích xuất giá trị số (Regex Extraction): Sử dụng biểu thức chính quy để tìm kiếm và tách riêng phần số từ các chuỗi hỗn hợp. Điều này cho phép chuyển đổi thông tin nhiệt độ từ dạng chữ sang dạng số nguyên (Integer), kể cả đối với nhiệt độ âm.
- Sắp xếp và chuẩn hóa thời gian: Dữ liệu được sắp xếp (Sort) theo trình tự thời gian thu thập và theo tên thành phố. Điều này giúp tạo ra một chuỗi dữ liệu liên tục, phục vụ cho việc quan sát sự biến thiên nhiệt độ.

- Xử lý giá trị trống (Missing Data): Tiến hành kiểm tra và loại bỏ hoàn toàn những dòng dữ liệu không có thông tin thành phố hoặc nhiệt độ bị lỗi, đảm bảo tập dữ liệu cuối cùng hoàn toàn sạch và có giá trị phân tích.

Bảng ví dụ chi tiết quá trình biến đổi:

Bảng 2.1: Các bước tiền xử lý và biến đổi dữ liệu

Thao tác xử lý	**Dữ liệu đầu vào (Input)**	**Kết quả đầu ra (Output)**	**Kỹ thuật áp dụng**
Làm sạch tên	Abidjan*	Abidjan	.replace("*","")
Tách nhiệt độ dương	Mon 14:02 31°C	31	Regex: (-?\d+)
Tách nhiệt độ âm	Mon 22:02 -27°C	-27	Regex: (-?\d+)
Loại bỏ dòng lỗi	(Dòng trống/NaN)	(Đã xóa)	.dropna()

Bảng kết quả bộ dữ liệu sạch:

Bảng 2.2: Dữ liệu sau khi làm sạch và tiền xử lý

city	**local_time**	**temperature**	**crawl_time**
Abidjan	Mon 14:02 31°C	31	2026-04-13 21:00:00
Zürich	Mon 15:02 9°C	9	2026-04-13 21:00:00
Tiksi	Mon 22:02 -27°C	-27	2026-04-13 21:00:00
Bangkok	Mon 21:02 34°C	34	2026-04-13 21:00:00

2.4 Xây dựng đặc trưng

2.4.1 Cho bài toán phân cụm

Trong bước này, dữ liệu nhiệt độ được xử lý nhằm xây dựng các đặc trưng theo từng thành phố.

Ban đầu, dữ liệu được đọc từ file CSV và tiến hành gom nhóm theo từng thành phố. Trên mỗi nhóm, các thống kê quan trọng của nhiệt độ được tính toán, bao gồm giá trị trung bình, nhỏ nhất, lớn nhất và độ lệch chuẩn.

Tiếp theo, một đặc trưng bổ sung là biên độ nhiệt được tạo ra bằng cách lấy hiệu giữa nhiệt độ lớn nhất và nhỏ nhất của từng thành phố. Sau khi hoàn tất, dữ liệu được làm tròn để đảm bảo tính nhất quán và dễ đọc, đồng thời được lưu lại thành một dataset mới phục vụ cho các bước tiếp theo.

Sau quá trình xây dựng đặc trưng, dữ liệu thu được được lưu trong file `city_features.csv` và được sử dụng trực tiếp cho Bài toán 1. Dataset này bao gồm tổng cộng **428 quan sát**, mỗi quan sát tương ứng với một thành phố, và **6 thuộc tính** mô tả đặc trưng nhiệt độ.

Các thuộc tính trong dataset bao gồm:

- `city`: tên thành phố
- `mean_temp`: nhiệt độ trung bình
- `min_temp`: nhiệt độ thấp nhất
- `max_temp`: nhiệt độ cao nhất

- `std_temp`: độ lệch chuẩn của nhiệt độ
- `range_temp`: biên độ nhiệt (max - min)

So với dữ liệu ban đầu, dataset mới đã được rút gọn đáng kể về số lượng dòng do quá trình gom nhóm theo thành phố. Tuy nhiên, mỗi quan sát lại mang nhiều thông tin tổng hợp hơn, giúp mô hình dễ dàng học được đặc trưng chung của từng khu vực.

Về mặt ý nghĩa, dataset này phù hợp để áp dụng cho Bài toán 1 vì dữ liệu đã được chuyển hoàn toàn về dạng số, thuận lợi cho các thuật toán học máy. Đồng thời, các đặc trưng như `mean_temp`, `std_temp` và `range_temp` giúp phân biệt rõ sự khác biệt về khí hậu giữa các thành phố. Việc tổng hợp dữ liệu cũng góp phần giảm nhiễu theo thời gian, giúp mô hình ổn định hơn khi huấn luyện.

Nhờ đó, các thuật toán như phân cụm hoặc phân loại có thể hoạt động hiệu quả hơn trên dataset này. Tuy nhiên, việc tổng hợp theo thành phố cũng đồng nghĩa với việc mất đi thông tin theo thời gian, do đó dataset không phù hợp với các bài toán dự báo chuỗi thời gian.

2.4.2 Cho bài toán phân loại

Trong Bài toán 2, dữ liệu được xây dựng theo hướng dự đoán trạng thái nhiệt độ tại thời điểm tiếp theo $(t + 1)$. Khác với Bài toán 1, dataset lần này giữ lại cấu trúc theo thời gian và bổ sung thêm các đặc trưng động nhằm phản ánh sự thay đổi của nhiệt độ.

Trước hết, dữ liệu được sắp xếp theo từng thành phố và theo thời gian để đảm bảo tính đúng thứ tự. Sau đó, một biến mục tiêu mới được tạo ra bằng cách lấy giá trị nhiệt độ tại thời điểm kế tiếp trong cùng một thành phố.

Để mô tả xu hướng biến đổi nhiệt độ, một đặc trưng động được xây dựng thông qua hiệu giữa nhiệt độ hiện tại và thời điểm trước đó. Bên cạnh đó, biến thời gian được mã hóa bằng các hàm sin và cos nhằm giữ được tính chu kỳ của dữ liệu theo ngày.

Tiếp theo, nhiệt độ tại thời điểm $t + 1$ được ánh xạ thành các nhãn rời rạc, bao gồm *cold*, *cool*, *warm* và *hot*, từ đó chuyển bài toán về dạng phân loại.

Sau khi hoàn tất các bước xử lý, các giá trị thiếu phát sinh do phép dịch chuyển được loại bỏ để đảm bảo dữ liệu sạch. Dataset cuối cùng chỉ giữ lại các đặc trưng cần thiết cho mô hình và được lưu lại để phục vụ huấn luyện.

Dataset sau khi xử lý được lưu trong file `DATASET_BAITOAN2.csv` và được sử dụng trực tiếp cho Bài toán 2. Kết quả cho thấy dataset gồm **9211 quan sát** và **6 thuộc tính**. Số lượng quan sát giảm so với dữ liệu ban đầu do việc tạo các biến dịch chuyển làm phát sinh giá trị thiếu, sau đó đã được loại bỏ.

Phân bố của biến mục tiêu cho thấy dữ liệu không hoàn toàn cân bằng giữa các lớp. Lớp `cold` chiếm tỷ lệ lớn nhất, trong khi lớp `hot` có số lượng thấp hơn đáng kể. Điều này có thể ảnh hưởng đến hiệu năng của mô hình nếu không có biện pháp xử lý phù hợp.

Dataset cuối cùng bao gồm các thuộc tính:

- `local_hour_24`: thời điểm trong ngày
- `temperature`: nhiệt độ hiện tại
- `delta_temp`: mức thay đổi nhiệt độ so với thời điểm trước
- `hour_sin`, `hour_cos`: đặc trưng mã hóa chu kỳ thời gian
- `label`: nhãn phân loại tại thời điểm tiếp theo

Về mặt ý nghĩa, dataset này cho phép mô hình học đồng thời trạng thái hiện tại và xu hướng biến đổi của nhiệt độ. Đặc biệt, biến `delta_temp` phản ánh xu hướng tăng hoặc giảm, trong khi `hour_sin` và `hour_cos` giúp mô hình nắm bắt được tính chu kỳ theo ngày.

Nhờ đó, dataset rất phù hợp cho các bài toán phân loại dự đoán ngắn hạn. Tuy nhiên, sự mất cân bằng giữa các lớp cần được lưu ý khi huấn luyện mô hình để tránh hiện tượng thiên lệch trong dự đoán.

Chương 3

Khám phá dữ liệu (EDA)

3.1 Thống kê mô tả

Để hiểu rõ đặc điểm của bộ dữ liệu, các thống kê mô tả cơ bản được tính toán cho hai biến chính là thời gian trong ngày (*local_hour_24*) và nhiệt độ (*temperature*).

Bảng 3.1: Thống kê mô tả các biến trong dữ liệu

Chỉ số	**Local Hour**	**Temperature**
Count	10067	10067
Mean	11.54	16.43
Std	6.91	12.23
Min	0	-32
25%	6	9
50% (Median)	12	18
75%	18	26
Max	23	43

Từ bảng thống kê mô tả, có thể nhận thấy biến *local_hour_24* phân bố đều trong khoảng từ 0 đến 23, với giá trị trung bình xấp xỉ 11.54, tương ứng với khoảng giữa ngày. Điều này cho thấy dữ liệu được thu thập đầy đủ trong 24 giờ.

Đối với biến *temperature*, giá trị trung bình là 16.43°C với độ lệch chuẩn khá lớn (12.23), cho thấy sự biến động nhiệt độ đáng kể trong tập dữ liệu. Nhiệt độ thấp nhất ghi nhận là -32°C và cao nhất là 43°C, phản ánh sự đa dạng về điều kiện khí hậu từ rất lạnh đến rất nóng.

Các giá trị phần vị (quartiles) cho thấy 50% dữ liệu nằm trong khoảng từ 9°C đến 26°C, trong khi trung vị là 18°C. Điều này cho thấy phần lớn các quan sát tập trung ở mức nhiệt độ trung bình đến ấm.

Nhìn chung, dữ liệu có sự phân bố rộng và đa dạng, tạo điều kiện thuận lợi cho việc áp dụng các phương pháp phân cụm để khám phá các nhóm nhiệt độ đặc trưng.

3.2 Kiểm tra dữ liệu thiếu

Để đảm bảo chất lượng dữ liệu trước khi tiến hành phân tích và xây dựng mô hình, bước kiểm tra giá trị thiếu (missing values) được thực hiện trên toàn bộ các cột trong tập dữ liệu.

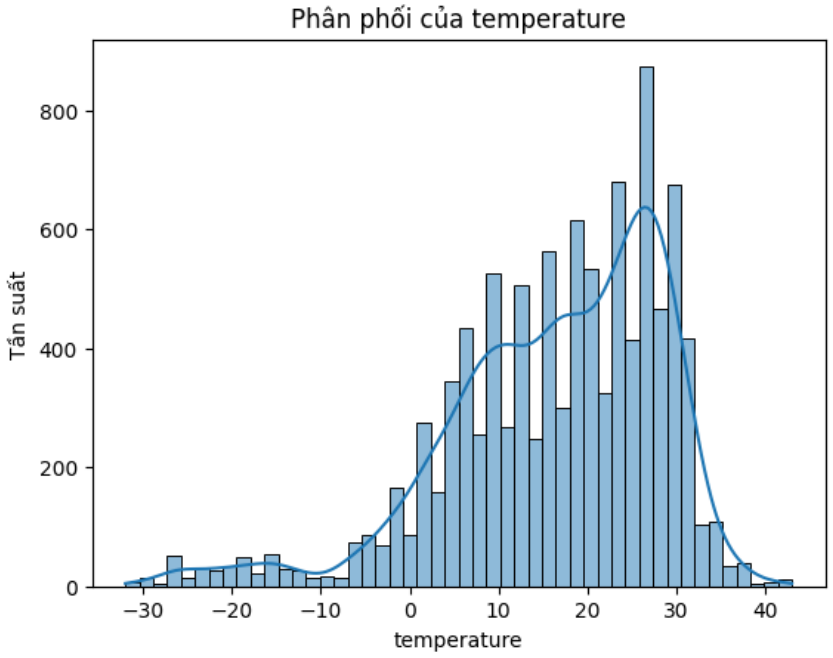
Kết quả kiểm tra cho thấy:

Bảng 3.2: Số lượng giá trị thiếu trong từng cột

Thuộc tính	**Số giá trị thiếu**
city	0
local_time	0
local_hour_24	0
temperature	0
crawl_time	0

Từ bảng trên có thể thấy rằng tất cả các thuộc tính trong bộ dữ liệu đều không chứa giá trị thiếu. Điều này cho thấy dữ liệu đã đầy đủ và không cần thực hiện các bước xử lý bổ sung như loại bỏ hoặc thay thế giá trị thiếu.

3.3 Phân phối dữ liệu



Hình 3.1: Biểu đồ phân phối temperature

Biểu đồ phân phối tần suất cho thấy đặc điểm phân bố của biến số nhiệt độ trên tập dữ liệu các thành phố như sau:

- Dữ liệu có xu hướng lệch trái, với phần lớn giá trị tập trung trong khoảng từ $10°C$ đến $30°C$. Đỉnh tần suất lớn nhất xuất hiện tại khoảng $26°C$

- Sự xuất hiện của nhiều đỉnh trên đường cong mật độ gợi ý rằng tập dữ liệu bao gồm các nhóm khí hậu khác nhau (ví dụ: các khu vực có khí hậu lạnh và nóng rõ rệt), dẫn đến phân phối không đồng nhất.

3.4 Nhận xét

Từ các phân tích khám phá dữ liệu (EDA), có thể rút ra một số nhận xét tổng quát như sau:

Thứ nhất, bộ dữ liệu có chất lượng tốt khi không chứa giá trị thiếu ở tất cả các thuộc tính. Điều này giúp đảm bảo tính đầy đủ và độ tin cậy cho các bước xử lý và mô hình hóa tiếp theo.

Thứ hai, các đặc trưng về thời gian (*local_hour_24*) có phân bố đồng đều trong khoảng từ 0 đến 23, cho thấy dữ liệu được thu thập liên tục và không bị thiên lệch theo thời gian.

Thứ ba, biến nhiệt độ (*temperature*) có phạm vi biến thiên rất rộng, từ -32°C đến 43°C, cùng với độ lệch chuẩn lớn (12.23), phản ánh sự đa dạng về điều kiện khí hậu giữa các thành phố. Phân phối dữ liệu có xu hướng lệch và xuất hiện nhiều đỉnh, cho thấy khả năng tồn tại nhiều nhóm dữ liệu khác biệt.

Chương 4

Tiền xử lý dữ liệu cho mô hình

Tiền xử lý dữ liệu (Data Preprocessing) là một trong những giai đoạn quan trọng nhất trong toàn bộ quy trình xây dựng mô hình học máy. Trong thực tế, dữ liệu thu thập từ nhiều nguồn thường tồn tại các vấn đề như thiếu giá trị, sai định dạng, dữ liệu nhiễu, trùng lặp hoặc chưa phù hợp để đưa trực tiếp vào thuật toán. Nếu không xử lý tốt ở giai đoạn này, mô hình dù sử dụng thuật toán mạnh vẫn có thể cho kết quả không chính xác hoặc khó hội tụ.

Đối với đề tài của nhóm, bộ dữ liệu chứa thông tin nhiệt độ của nhiều thành phố tại các thời điểm khác nhau. Dữ liệu được sử dụng cho hai bài toán:

- **Bài toán 1:** Phân cụm thành phố theo đặc trưng nhiệt độ.
- **Bài toán 2:** Xây dựng mô hình dự đoán trạng thái nhiệt độ.

Do đó, nhóm đã tiến hành các bước tiền xử lý dữ liệu nhằm đảm bảo chất lượng đầu vào cho mô hình học máy. Các bước này giúp dữ liệu trở nên sạch hơn, nhất quán hơn và phù hợp với yêu cầu của các thuật toán.

Cụ thể, nhóm tập trung vào việc nâng cao chất lượng dữ liệu đầu vào, loại bỏ các yếu tố gây nhiễu có thể ảnh hưởng đến kết quả mô hình, đồng thời chuẩn hóa dữ liệu để đảm bảo các đặc trưng có cùng thang đo. Bên cạnh đó, việc lựa chọn các đặc trưng phù hợp cũng được thực hiện nhằm giữ lại những thông tin quan trọng nhất cho bài toán.

Cuối cùng, dữ liệu được chia thành tập huấn luyện và tập kiểm tra để phục vụ cho quá trình xây dựng và đánh giá mô hình một cách khách quan và chính xác.

Sau khi khảo sát ban đầu, bộ dữ liệu gồm **10.067 dòng dữ liệu** và **5 cột thuộc tính**, bao gồm:

STT	**Thuộc tính**	**Kiểu dữ liệu**	**Ý nghĩa**
1	city	object	Tên thành phố
2	local_time	object	Thời gian địa phương
3	local_hour_24	int64	Giờ trong ngày (0–23)
4	temperature	float64	Nhiệt độ hiện tại
5	crawl_time	object	Thời điểm hệ thống thu thập dữ liệu

4.1 Làm sạch dữ liệu

Làm sạch dữ liệu là bước đầu tiên nhằm đảm bảo bộ dữ liệu có tính nhất quán, chính xác và đáng tin cậy trước khi huấn luyện mô hình.

4.1.1 Mô tả dữ liệu ban đầu

Cột `local_time` chứa thông tin về thứ trong tuần và giờ:phút (ví dụ: Sun 17:52), tuy nhiên lại không bao gồm ngày cụ thể. Trong khi đó, cột `crawl_time` cung cấp đầy đủ thông tin ngày và giờ (ví dụ: 2026-04-13 00:51:35), nên có thể dùng làm mốc thời gian chính.

Vấn đề đặt ra là `local_time` không thể sử dụng trực tiếp cho các phân tích theo thời gian do thiếu thông tin ngày, dẫn đến khó xác định chính xác thời điểm ghi nhận dữ liệu. Ngoài ra, hai cột này có định dạng khác nhau, gây ra sự không đồng nhất trong quá trình xử lý và phân tích dữ liệu.

4.1.2 Phương pháp chuẩn hóa

Trong quá trình tiền xử lý dữ liệu, ngày được trích xuất từ cột `crawl_time`, trong khi phần thời gian giờ:phút được lấy từ cột `local_time`. Việc này nhằm đảm bảo rằng cả hai thành phần thời gian (ngày và giờ) đều được sử dụng đầy đủ thay vì chỉ dựa trên một nguồn riêng lẻ. Sau khi tách và chuẩn hóa, các giá trị này sẽ được xử lý để đảm bảo tính nhất quán về định dạng trước khi ghép lại.

Tiếp theo, hai thành phần ngày và giờ được kết hợp để tạo thành một cột mới có tên `local_datetime`. Cột này được chuẩn hóa theo định dạng `YYYY-MM-DD HH:MM:SS`, giúp dữ liệu thời gian trở nên thống nhất, dễ đọc và thuận tiện hơn cho các bước phân tích, trực quan hóa và xây dựng mô hình sau này.

4.1.3 Kết quả sau chuẩn hóa

- Tổng số bản ghi: 10,067.
- Số bản ghi lỗi: 0.
- Dữ liệu sau xử lý: 100% hợp lệ.

Phạm vi thời gian:

- Thời điểm sớm nhất: 2026-04-13 00:04:00.
- Thời điểm muộn nhất: 2026-04-13 23:52:00.

Dữ liệu trải đều trong toàn bộ 24 giờ.

4.1.4 Nhận xét

Dữ liệu thời gian sau khi xử lý đã được chuẩn hóa hoàn toàn, đảm bảo tính thống nhất về định dạng và có thể sử dụng trực tiếp cho các bước phân tích tiếp theo. Nhờ đó, dữ liệu trở nên phù hợp để thực hiện các phân tích theo giờ, giúp khai thác được các xu hướng biến động theo thời gian trong ngày. Đồng thời, bộ dữ liệu này cũng đã sẵn sàng để phục vụ cho việc xây dựng mô hình dự đoán trong các bài toán học máy.

Bên cạnh đó, trong quá trình xử lý không ghi nhận dữ liệu bị mất hoặc sai định dạng, đảm bảo tính toàn vẹn của tập dữ liệu. Việc kết hợp hai cột `crawl_time` và `local_time` cũng giúp tận dụng tối đa thông tin sẵn có, tạo ra một biến thời gian đầy đủ và có ý nghĩa hơn, từ đó nâng cao chất lượng cho các bước phân tích và mô hình hóa sau này.

4.2 Lựa chọn đặc trưng

Feature Selection là bước lựa chọn các biến đầu vào quan trọng nhất cho mô hình nhằm đảm bảo hiệu quả trong quá trình học máy. Việc đưa quá nhiều đặc trưng không cần thiết có thể gây ra nhiều vấn đề như làm nhiễu dữ liệu, tăng thời gian huấn luyện, giảm độ chính xác của mô hình và dễ dẫn đến hiện tượng overfitting.

Do đó, việc lựa chọn đặc trưng phù hợp đóng vai trò rất quan trọng trong việc tối ưu hiệu suất mô hình. Vì đề tài bao gồm hai bài toán khác nhau, nên nhóm đã tiến hành lựa chọn tập đặc trưng riêng cho từng bài toán để đảm bảo mỗi mô hình đều sử dụng đúng những thông tin có ý nghĩa nhất, từ đó nâng cao hiệu quả dự đoán và tính ổn định của hệ thống.

4.2.1 Đặc trưng cho bài toán phân cụm thành phố

Mục tiêu là nhóm các thành phố có đặc điểm nhiệt độ tương đồng.

Không sử dụng trực tiếp cột `city`, nhóm tổng hợp dữ liệu theo từng thành phố

Các đặc trưng thu được:

Đặc trưng	**Ý nghĩa**
mean	Nhiệt độ trung bình
max	Nhiệt độ cao nhất
min	Nhiệt độ thấp nhất
std	Mức dao động nhiệt độ

Những đặc trưng này phản ánh rõ khí hậu của từng thành phố.

4.2.2 Đặc trưng cho bài toán dự đoán trạng thái nhiệt độ

Nhóm tạo nhãn phân loại từ cột `temperature`.

Ví dụ:

Nhiệt độ	**Nhãn**
< 20	Lạnh
$20 - 30$	Mát
> 30	Nóng

Sau đó, nhóm tiến hành lựa chọn các đặc trưng đầu vào quan trọng để phục vụ cho mô hình học máy. Các đặc trưng này bao gồm thông tin về `city`, giúp phân biệt điều kiện nhiệt độ giữa các khu vực khác nhau, và `local_hour_24`, phản ánh sự thay đổi nhiệt độ theo từng khung giờ trong ngày.

Ngoài ra, các đặc trưng thời gian như ngày trong tuần và tháng cũng được đưa vào để khai thác các xu hướng theo chu kỳ dài hơn. Nhóm cũng bổ sung thêm đặc trưng giờ cao điểm và thấp điểm nhằm thể hiện rõ hơn sự biến động nhiệt độ theo hoạt động trong ngày. Cuối cùng, kỹ thuật cyclical encoding của giờ được sử dụng để biểu diễn tính tuần hoàn của thời gian, giúp mô hình học tốt hơn các mối quan hệ theo chu kỳ.

4.2.3 Mã hóa biến phân loại

Cột `city` là dữ liệu dạng chữ nên cần chuyển sang dạng số.

Ví dụ:

Thành phố	Mã
Hanoi	0
Tokyo	1
Paris	2

4.3 Chuẩn hóa dữ liệu

Chuẩn hóa dữ liệu giúp đưa các đặc trưng về cùng một thang đo, từ đó đảm bảo rằng không có biến nào bị chi phối quá mức do đơn vị lớn hơn. Điều này đặc biệt quan trọng trong các thuật toán dựa trên khoảng cách và tối ưu hóa.

Cụ thể, với K-Means, việc phân cụm dựa trên khoảng cách Euclidean nên nếu các đặc trưng không được chuẩn hóa, những biến có giá trị lớn sẽ ảnh hưởng mạnh đến kết quả phân cụm. Tương tự, trong Logistic Regression và Softmax Regression, quá trình tối ưu bằng Gradient Descent sẽ trở nên ổn định và hiệu quả hơn khi các đặc trưng có cùng thang đo, giúp mô hình hội tụ nhanh và chính xác hơn.

Ví dụ:

Đặc trưng	Giá trị
Hour	0–23
Temperature	-5 đến 40

Nếu không chuẩn hóa, nhiệt độ sẽ chi phối mô hình mạnh hơn giờ.

4.3.1 Phương pháp StandardScaler

Nhóm sử dụng công thức:

$$z = \frac{x - \mu}{\sigma}$$

Trong đó, μ (mu) là giá trị trung bình của dữ liệu và σ (sigma) là độ lệch chuẩn, thể hiện mức độ phân tán của dữ liệu so với trung bình.

Sau khi áp dụng chuẩn hóa (standardization), các đặc trưng được đưa về cùng một thang đo với giá trị trung bình bằng 0 (Mean = 0) và độ lệch chuẩn bằng 1 (Std = 1). Diều này giúp dữ liệu trở nên đồng nhất hơn, hỗ trợ mô hình học máy hoạt động ổn định và hiệu quả hơn trong quá trình huấn luyện.

4.3.2 Lợi ích

Việc chuẩn hóa và xử lý đặc trưng đầu vào mang lại nhiều lợi ích rõ rệt cho quá trình huấn luyện mô hình. Trước hết, mô hình có thể học nhanh hơn do các đặc trưng được đưa về cùng một thang đo, giúp quá trình tối ưu tham số diễn ra hiệu quả hơn.

Bên cạnh đó, thuật toán Gradient Descent cũng hội tụ ổn định và nhanh hơn, hạn chế tình trạng dao động hoặc hội tụ chậm trong quá trình huấn luyện. Việc chuẩn hóa

dữ liệu còn giúp giảm sự thiên lệch giữa các đặc trưng, đảm bảo rằng không có biến nào chi phối quá mức so với các biến còn lại.

Cuối cùng, nhờ các yếu tố trên, độ chính xác tổng thể của mô hình cũng được cải thiện, giúp kết quả dự đoán trở nên ổn định và đáng tin cậy hơn.

4.4 Chia tập dữ liệu

Sau khi hoàn tất bước tiền xử lý, dữ liệu được chia thành hai tập chính để phục vụ quá trình xây dựng và đánh giá mô hình. Tập Training Set được sử dụng để huấn luyện mô hình, giúp mô hình học được các mối quan hệ và quy luật từ dữ liệu đầu vào.

Trong khi đó, tập Testing Set được dùng để kiểm tra và đánh giá hiệu suất của mô hình trên dữ liệu chưa từng thấy trước đó. Việc phân chia này giúp đảm bảo mô hình không bị học thuộc dữ liệu (overfitting) và có khả năng tổng quát hóa tốt khi áp dụng vào dữ liệu thực tế.

4.4.1 Tỷ lệ chia dữ liệu

Nhóm sử dụng tỷ lệ phổ biến:

- 80% train
- 20% test

Kết quả:

- Train size: 8053
- Test size: 2014

4.4.2 Vai trò của train/test split

Tập Training Set được sử dụng trong quá trình huấn luyện mô hình nhằm giúp mô hình học các quy luật và mối quan hệ trong dữ liệu. Thông qua tập dữ liệu này, mô hình thực hiện việc tính toán và điều chỉnh các trọng số, đồng thời tối ưu hàm mất mát (loss function) để đạt được hiệu quả dự đoán tốt nhất.

Ngược lại, tập Testing Set được sử dụng để đánh giá khả năng hoạt động của mô hình trên dữ liệu chưa từng được nhìn thấy trong quá trình huấn luyện. Tập này giúp kiểm tra khả năng tổng quát hóa của mô hình, đồng thời được dùng để tính các chỉ số đánh giá như Accuracy, Precision và Recall. Bên cạnh đó, việc sử dụng tập kiểm tra cũng giúp phát hiện hiện tượng overfitting, tức là khi mô hình học quá sát dữ liệu huấn luyện nhưng hoạt động kém trên dữ liệu mới.

Chương 5

Áp dụng mô hình học máy

Sau khi hoàn thành các bước thu thập, xử lý và chuẩn hóa dữ liệu, giai đoạn tiếp theo của đề tài là áp dụng các mô hình học máy nhằm khai thác thông tin có giá trị từ bộ dữ liệu nhiệt độ. Đây là nội dung trọng tâm của toàn bộ đồ án vì kết quả của các mô hình sẽ phản ánh khả năng học từ dữ liệu, phát hiện quy luật tiềm ẩn và hỗ trợ dự đoán trên dữ liệu mới.

Bộ dữ liệu của nhóm chứa thông tin về nhiều thành phố trên thế giới, thời gian địa phương và nhiệt độ tương ứng tại thời điểm thu thập. Với cấu trúc dữ liệu như vậy, nhóm triển khai hai hướng nghiên cứu chính:

- Phân cụm các thành phố theo đặc trưng nhiệt độ.
- Xây dựng mô hình dự đoán trạng thái nhiệt độ.

Hai hướng nghiên cứu này tương ứng với hai nhánh quan trọng trong Machine Learning là học không giám sát và học có giám sát. Việc kết hợp cả hai phương pháp giúp đề tài vừa có khả năng khám phá dữ liệu, vừa có khả năng xây dựng hệ thống dự đoán phục vụ ứng dụng thực tiễn.

5.1 Tổng quan phương pháp

Machine Learning trong đề tài

Machine Learning là phương pháp cho phép máy tính học từ dữ liệu để tự động rút ra quy luật thay vì xây dựng hoàn toàn bằng các quy tắc thủ công. Khi được cung cấp dữ liệu phù hợp, mô hình có thể nhận diện mẫu, dự đoán kết quả hoặc chia nhóm dữ liệu dựa trên mức độ tương đồng.

Trong đề tài này, nhóm lựa chọn hai hướng tiếp cận phù hợp với bản chất của bộ dữ liệu.

Phương pháp phân cụm dữ liệu

Dữ liệu nhiệt độ ban đầu không có nhãn xác định trước, tức là không có thông tin thành phố thuộc nhóm khí hậu nào. Do đó, nhóm sử dụng thuật toán phân cụm để tự động chia dữ liệu thành các nhóm có đặc điểm tương đồng.

Thuật toán được lựa chọn là K-Means vì đây là phương pháp phổ biến, hiệu quả và phù hợp với dữ liệu dạng số sau khi chuẩn hóa. Kết quả phân cụm giúp nhận diện các

nhóm thành phố có nhiệt độ gần nhau, từ đó hỗ trợ phân tích khí hậu và so sánh giữa các khu vực.

Phương pháp phân loại dữ liệu

Ngoài việc khám phá dữ liệu, nhóm còn xây dựng mô hình dự đoán trạng thái nhiệt độ. Từ giá trị nhiệt độ thực tế, nhóm chuyển đổi thành các nhãn phân loại để mô hình học cách dự đoán trạng thái nhiệt độ dựa trên các đặc trưng đầu vào.

Trong bài toán này, hai mô hình chính được sử dụng để thực hiện phân loại trạng thái nhiệt độ. Mô hình đầu tiên là Logistic Regression, một thuật toán phổ biến trong học máy dùng để giải quyết các bài toán phân loại nhị phân, dựa trên việc ước lượng xác suất thông qua hàm sigmoid.

Mô hình thứ hai là Softmax Regression được tự triển khai từ đầu nhằm mở rộng Logistic Regression cho bài toán phân loại đa lớp. Việc tự xây dựng giúp hiểu rõ hơn cơ chế tính toán, cách cập nhật trọng số và quá trình tối ưu hóa trong từng vòng lặp, đồng thời cho phép so sánh trực tiếp với phiên bản sử dụng thư viện chuẩn.

Nhóm lựa chọn các mô hình này vì có nền tảng toán học rõ ràng, tốc độ huấn luyện nhanh và phù hợp với bài toán phân loại nhiều lớp.

Ý nghĩa của việc kết hợp nhiều mô hình

Việc kết hợp đồng thời cả phân cụm và phân loại giúp đề tài có chiều sâu nghiên cứu hơn và mang tính toàn diện trong phân tích dữ liệu. Trong đó, phân cụm được sử dụng để khám phá các cấu trúc tiềm ẩn trong dữ liệu, giúp nhận diện các nhóm thành phố có đặc điểm nhiệt độ tương đồng mà không cần nhãn trước.

Trong khi đó, phân loại được áp dụng để xây dựng hệ thống dự đoán trên dữ liệu mới, cho phép xác định trạng thái nhiệt độ dựa trên các đặc trưng đã học. Ngoài ra, việc so sánh giữa mô hình tự xây dựng và mô hình sử dụng thư viện còn giúp đánh giá rõ hơn hiệu quả thực tế của từng phương pháp, từ đó làm nổi bật sự khác biệt giữa việc hiểu bản chất thuật toán và việc áp dụng các công cụ tối ưu sẵn có.

5.1.1 Phân loại bài toán

Phân loại bài toán trong đề tài

Dựa trên mục tiêu nghiên cứu và đặc điểm dữ liệu, nhóm xác định đề tài bao gồm hai loại bài toán chính.

Bài toán học không giám sát:

Ở giai đoạn đầu, bộ dữ liệu không chứa nhãn đầu ra. Mỗi bản ghi chỉ phản ánh thông tin nhiệt độ và thời gian tại từng thành phố. Vì không có đáp án đúng cho từng mẫu dữ liệu, nhóm sử dụng học không giám sát để tìm ra các nhóm dữ liệu có mức độ tương đồng cao.

Sau bước phân tích dữ liệu ban đầu, nhóm xây dựng nhãn trạng thái nhiệt độ từ cột nhiệt độ. Khi đó, dữ liệu đã có biến mục tiêu và có thể sử dụng các thuật toán học có giám sát để huấn luyện mô hình dự đoán.

Mục tiêu của bài toán này là xây dựng mô hình có khả năng học được mối quan hệ giữa các đặc trưng đầu vào và trạng thái nhiệt độ tương ứng. Thông qua đó, mô hình có thể hiểu được cách các yếu tố dữ liệu ảnh hưởng đến kết quả đầu ra.

Bên cạnh đó, mô hình được sử dụng để dự đoán nhãn trạng thái nhiệt độ cho các dữ liệu mới chưa từng xuất hiện trong quá trình huấn luyện. Đồng thời, việc đánh giá độ chính xác của mô hình cũng được thực hiện nhằm kiểm tra mức độ hiệu quả và độ tin cậy của hệ thống.

Đây là một dạng bài toán phổ biến trong thực tế, có tính ứng dụng cao trong các lĩnh vực dự báo và hỗ trợ ra quyết định, đặc biệt trong các hệ thống liên quan đến thời tiết và phân tích dữ liệu môi trường.

Việc kết hợp cả hai dạng bài toán mang lại nhiều lợi ích rõ rệt cho quá trình nghiên cứu và phát triển mô hình. Trước hết, nó giúp tăng tính toàn diện cho đề tài, khi vừa xem xét được cấu trúc dữ liệu, vừa xây dựng được mô hình dự đoán trên cùng một hệ thống. Bên cạnh đó, phương pháp này cho phép vừa khám phá dữ liệu thông qua phân cụm, vừa tạo ra khả năng dự đoán thông qua phân loại, từ đó khai thác dữ liệu một cách hiệu quả hơn. Đồng thời, dữ liệu cũng được đánh giá dưới nhiều góc nhìn khác nhau, giúp hiểu rõ hơn về đặc điểm và mối quan hệ giữa các yếu tố. Cuối cùng, việc kết hợp này góp phần nâng cao giá trị ứng dụng thực tế của hệ thống, giúp mô hình không chỉ có ý nghĩa nghiên cứu mà còn có khả năng áp dụng vào các bài toán thực tiễn.

5.1.2 Quy trình huấn luyện

Sau khi xác định bài toán và lựa chọn mô hình phù hợp, nhóm triển khai quy trình huấn luyện theo các bước tiêu chuẩn trong khoa học dữ liệu.

Bước 1: Chuẩn bị dữ liệu

Dữ liệu sau tiền xử lý được sử dụng làm đầu vào cho mô hình học máy. Ở bước này, dữ liệu đã được làm sạch, loại bỏ các biến không phù hợp, đồng thời các biến dạng chữ được mã hóa về dạng số và các đặc trưng số được chuẩn hóa để đảm bảo đồng nhất thang đo. Ngoài ra, biến mục tiêu cũng được xây dựng phù hợp cho bài toán phân loại. Đây là bước quan trọng vì ảnh hưởng trực tiếp đến chất lượng và độ chính xác của mô hình.

Bước 2: Chia dữ liệu huấn luyện và kiểm tra

Cách chia này giúp hạn chế hiện tượng ghi nhớ dữ liệu và phản ánh chính xác khả năng tổng quát hóa của mô hình.

Bước 3: Huấn luyện mô hình phân cụm

Đối với bài toán phân cụm, mô hình được huấn luyện bằng cách lặp lại quá trình xác định tâm cụm và gán điểm dữ liệu vào cụm gần nhất cho đến khi các tâm cụm ổn định.

Bước 4: Huấn luyện mô hình phân loại

Đối với bài toán phân loại, mô hình được huấn luyện bằng cách tối ưu hàm mất mát để tìm ra bộ trọng số tốt nhất. Quá trình huấn luyện diễn ra qua nhiều vòng lặp cho đến khi mô hình hội tụ.

Bước 5: Đánh giá mô hình

Sau khi huấn luyện, các mô hình được đánh giá bằng các chỉ số phù hợp với từng bài toán nhằm đảm bảo kết quả khách quan và đáng tin cậy.

Đối với bài toán phân cụm, mô hình được đánh giá dựa trên mức độ chặt chẽ của các cụm và khoảng cách giữa các cụm, từ đó xác định khả năng phân tách dữ liệu của thuật toán.

Đối với bài toán phân loại, các chỉ số như Accuracy, Precision, Recall, F1-score cùng với ma trận nhầm lẫn (Confusion Matrix) được sử dụng để đánh giá hiệu quả dự đoán của mô hình. Những chỉ số này giúp phản ánh chính xác chất lượng mô hình trong việc phân loại dữ liệu.

Bước 6: So sánh và phân tích

Nhóm tiến hành so sánh giữa mô hình tự xây dựng và mô hình sử dụng thư viện nhằm đánh giá sự khác biệt trong cách tiếp cận và hiệu quả thực tế. Đồng thời, các thuật toán khác nhau cũng được so sánh để làm rõ mức độ phù hợp trong từng trường hợp cụ thể.

Bên cạnh đó, nhóm xem xét thêm các yếu tố như tốc độ xử lý, độ chính xác, cũng như khả năng mở rộng và ứng dụng trong thực tế. Thông qua quá trình so sánh này, nhóm rút ra được các nhận xét về ưu điểm, hạn chế của từng phương pháp, từ đó đánh giá mức độ phù hợp của chúng đối với bộ dữ liệu nhiệt độ đã sử dụng.

5.2 Bài toán 1: Phân cụm thành phố

5.2.1 Thuật toán K-Means

Giới thiệu

Thuật toán K-means là một phương pháp phân cụm phổ biến trong học không giám sát (unsupervised learning), thuộc lĩnh vực Machine Learning. Mục tiêu của thuật toán là phân chia tập dữ liệu thành k cụm sao cho các phần tử trong cùng một cụm có độ tương đồng cao, trong khi các cụm khác nhau có sự khác biệt rõ rệt.

Mỗi cụm được đại diện bởi một điểm trung tâm (centroid), được tính bằng trung bình của các điểm dữ liệu thuộc cụm đó.

Hàm mục tiêu

Thuật toán K-means tối thiểu hóa tổng bình phương khoảng cách giữa các điểm dữ liệu và tâm cụm tương ứng. Hàm mục tiêu được biểu diễn như sau:

$$J = \sum_{i=1}^{k} \sum_{x \in C_i} \|x - \mu_i\|^2 \tag{5.1}$$

Trong đó:

- k là số cụm
- C_i là tập các điểm thuộc cụm thứ i
- μ_i là tâm cụm thứ i
- x là một điểm dữ liệu

Mục tiêu là tìm cách phân cụm sao cho giá trị J đạt nhỏ nhất.

Quy trình thuật toán

Thuật toán K-means được thực hiện thông qua các bước lặp sau:

1. **Khởi tạo:** Chọn ngẫu nhiên k điểm làm tâm cụm ban đầu.
2. **Gán cụm (Assignment step):** Mỗi điểm dữ liệu được gán vào cụm có tâm gần nhất, thường dựa trên khoảng cách Euclid.

3. **Cập nhật tâm cụm (Update step):** Tính lại tâm cụm bằng trung bình của các điểm thuộc cụm:
$$\mu_i = \frac{1}{|C_i|} \sum_{x \in C_i} x \tag{5.2}$$

4. **Lặp:** Lặp lại hai bước trên cho đến khi các tâm cụm không còn thay đổi hoặc đạt số vòng lặp tối đa.

Ứng dụng
Thuật toán K-means được ứng dụng rộng rãi trong nhiều lĩnh vực như:

- Phân cụm khách hàng trong marketing
- Khai phá dữ liệu (data mining)
- Nén ảnh và xử lý ảnh
- Nhận dạng mẫu (pattern recognition)

5.2.2 Triển khai K-Means từ đầu

Ý TƯỞNG HUẤN LUYỆN MÔ HÌNH

Mục tiêu

Bài toán đặt ra là phân nhóm các thành phố dựa trên đặc điểm nhiệt độ nhằm khám phá cấu trúc ẩn trong dữ liệu. Cụ thể, mục tiêu là tự động chia các thành phố thành các nhóm có khí hậu tương đồng mà không cần nhãn có sẵn, đồng thời tạo ra dữ liệu đã được phân cụm để phục vụ cho các bài toán phân tích và ứng dụng ở các bước tiếp theo.

Phương pháp sử dụng

Bài toán được tiếp cận theo hướng học không giám sát (Unsupervised Learning), phù hợp với trường hợp dữ liệu không có nhãn. Thuật toán được lựa chọn là K-Means Clustering, một phương pháp phổ biến với cơ chế hoạt động lặp.

Ở mỗi vòng lặp, các điểm dữ liệu được gán vào cụm có tâm gần nhất, sau đó tâm cụm được cập nhật lại dựa trên trung bình của các điểm trong cụm. Quá trình này tiếp tục cho đến khi các cụm ổn định. Phương pháp này có ưu điểm là đơn giản, dễ triển khai và cho kết quả trực quan.

Kiến thức nền tảng

Phân cụm dữ liệu

Phân cụm là quá trình chia dữ liệu thành các nhóm sao cho các điểm trong cùng một cụm có mức độ tương đồng cao, trong khi các điểm ở các cụm khác nhau có sự khác biệt rõ rệt. Đây là một dạng học không giám sát vì mô hình tự phát hiện cấu trúc trong dữ liệu mà không cần nhãn.

Khoảng cách Euclidean

Độ tương đồng giữa các điểm dữ liệu được đo bằng khoảng cách Euclidean trong không gian nhiều chiều. Khoảng cách này phản ánh mức độ gần nhau giữa hai vector đặc trưng và được sử dụng để xác định cụm gần nhất trong quá trình phân cụm.

$$d(x, c) = \sqrt{\sum_i (x_i - c_i)^2}$$

Biểu diễn dữ liệu

Mỗi thành phố được biểu diễn bằng một vector đặc trưng gồm 5 chiều, trong đó mỗi chiều là một đại lượng thống kê liên quan đến nhiệt độ. Vector này đóng vai trò là đầu vào trực tiếp cho thuật toán K-Means.

Ý tưởng cốt lõi

Thuật toán K-Means được triển khai theo cơ chế lặp gồm hai bước chính: gán cụm và cập nhật tâm cụm. Quá trình này được thực hiện liên tục cho đến khi các tâm cụm không còn thay đổi đáng kể, tức là mô hình đã hội tụ.

Lựa chọn số cụm K tối ưu

Việc xác định số cụm K phù hợp là một bước quan trọng trong K-Means. Trong bài toán này, hai phương pháp được sử dụng kết hợp để đưa ra lựa chọn tối ưu.

Phương pháp Elbow dựa trên việc quan sát sự thay đổi của tổng bình phương khoảng cách (Inertia) khi số cụm tăng dần. Giá trị K được chọn tại điểm mà tốc độ giảm của Inertia bắt đầu chậm lại.

Bên cạnh đó, Silhouette Score được sử dụng để đánh giá mức độ phù hợp của từng điểm với cụm của nó. Giá trị này càng cao thì chất lượng phân cụm càng tốt.

Kết quả thực nghiệm cho thấy Silhouette Score đạt giá trị cao nhất tại K = 4, do đó đây là giá trị được lựa chọn cho mô hình.

Bảng 5.1: Kết quả chọn K theo Elbow và Silhouette Score

K	**Inertia (tham khảo)**	**Silhouette Score**	**Ghi chú**
2	Cao	Thấp	Phân chia quá thô
3	Trung bình	Trung bình	
4	Vừa phải	Cao nhất	K được chọn
5+	Thấp	Giảm dần	Phân chia quá mịn

Kết quả đầu ra

Sau khi huấn luyện với K = 4, mỗi thành phố được gán một nhãn cụm thuộc tập $\{0, 1, 2, 3\}$. Nhãn này được lưu trong cột *cluster* của dữ liệu và là kết quả chính của quá trình phân cụm.

Bảng 5.2: Đặc trưng trung bình của 4 cụm thành phố (output từ notebook)

Cluster	mean_temp	min_temp (°C)	max_temp (°C)	std_temp	range_temp
0–Nóng	25,09	22,11	28,36	2,14	6,25
1–lạnh	–17,22	–21,75	–12,65	3,18	9,10
2–ấm	17,04	10,18	24,04	4,87	13,85
3–Mát	7,52	4,42	10,73	2,11	6,31

Trực quan hóa kết quả

Kết quả phân cụm được trực quan hóa thông qua các biểu đồ scatter. Biểu đồ thứ nhất thể hiện sự phân bố của các cụm trong không gian đặc trưng, trong khi biểu đồ thứ hai bổ sung thêm vị trí của các tâm cụm.

Việc đưa tâm cụm về không gian nhiệt độ gốc giúp việc diễn giải ý nghĩa của từng cụm trở nên trực quan và dễ hiểu hơn.

Ý nghĩa thực tế

Dựa trên các đặc trưng trung bình của từng cụm, các nhóm thành phố có thể được diễn giải theo các kiểu khí hậu khác nhau. Kết quả này có thể được ứng dụng trong nhiều bài toán thực tế như xây dựng hệ thống IoT theo vùng khí hậu, làm đặc trưng đầu vào cho các mô hình học có giám sát, hoặc phân tích xu hướng khí hậu theo khu vực.

Bảng 5.3: Diễn giải ý nghĩa thực tế của 4 cụm thành phố

Cluster	Đặc điểm khí hậu	Ứng dụng tiêu biểu
0 – Nóng ẩm	Nhiệt độ trung bình cao (25°C), biên độ nhiệt nhỏ, ổn định	Vùng nhiệt đới, hệ thống làm mát
1 – Rất lạnh	Nhiệt độ âm (–17°C), biên độ nhiệt trung bình	Vùng cực/cận cực, hệ thống sưởi ấm
2 – Ôn đới mát	Nhiệt độ vừa phải (17°C), biên độ nhiệt lớn nhất (14°C)	Vùng ôn đới, hệ thống HVAC linh hoạt
3 – Mát mẻ ổn định	Nhiệt độ thấp nhẹ (7.5°C), biên độ nhiệt nhỏ nhất, rất ổn định	Vùng á hàn đới, thiết bị IoT ổn nhiệt

Tổng kết

Bảng 5.4: Tóm tắt luồng xử lý từ dữ liệu đến kết quả phân cụm

Bước	Thao tác	Công cụ / Kết quả
1	Tải dữ liệu	`pd.read_csv("DATASET_BAITOAN1.csv")`
2	Chọn 5 đặc trưng nhiệt độ	mean, min, max, std, range_temp
3	Chuẩn hóa dữ liệu	StandardScaler → X_scaled
4	Chọn số cụm tối ưu	Elbow + Silhouette → K = 4
5	Huấn luyện K-Means (tự cài đặt)	kmeans(X_scaled, k=4)
6	Gán nhãn cụm	df["cluster"] = labels
7	Thống kê và trực quan hóa	groupby + scatter plot

Toàn bộ quy trình từ dữ liệu đầu vào đến kết quả phân cụm bao gồm các bước: tiền xử lý dữ liệu, xây dựng vector đặc trưng, lựa chọn số cụm tối ưu, huấn luyện mô hình K-Means và phân tích kết quả đầu ra.

5.2.3 Sử dụng thư viện (Sklearn)

Quá trình triển khai mô hình phân cụm được thực hiện bằng thư viện *scikit-learn* trong Python. Thư viện này cung cấp các công cụ hỗ trợ tiền xử lý dữ liệu và xây dựng mô hình học máy một cách hiệu quả.

Tiền xử lý dữ liệu: Bộ dữ liệu ban đầu bao gồm các đặc trưng liên quan đến nhiệt độ của các thành phố như: nhiệt độ trung bình (mean), nhiệt độ thấp nhất (min), nhiệt độ cao nhất (max), độ lệch chuẩn (std) và khoảng nhiệt (range). Trong quá trình xử lý, cột *city* được loại bỏ vì đây là biến dạng văn bản, không phù hợp với các thuật toán phân cụm dựa trên khoảng cách.

Chuẩn hóa dữ liệu: Các đặc trưng được chuẩn hóa bằng công cụ *StandardScaler* để đưa về cùng thang đo với trung bình bằng 0 và độ lệch chuẩn bằng 1. Bước này là cần thiết vì thuật toán K-Means sử dụng khoảng cách Euclidean, do đó các đặc trưng có giá trị lớn có thể ảnh hưởng không cân đối đến kết quả phân cụm nếu không được chuẩn hóa.

Lựa chọn số cụm: Số cụm được lựa chọn là $k = 4$, tương ứng với giả định dữ liệu có thể được chia thành ba nhóm khí hậu chính như lạnh, ôn hòa và nóng. Giá trị này có thể được điều chỉnh tùy theo mục tiêu phân tích.

Huấn luyện mô hình: Thuật toán *K-Means* được sử dụng để phân chia dữ liệu thành 4 cụm. Quá trình huấn luyện bao gồm:

- Khởi tạo các tâm cụm ban đầu
- Gán mỗi điểm dữ liệu vào cụm có tâm gần nhất
- Cập nhật lại tâm cụm dựa trên trung bình của các điểm trong cụm
- Lặp lại cho đến khi mô hình hội tụ

Kết quả phân cụm: Sau khi huấn luyện, mỗi điểm dữ liệu được gán một nhãn cụm (cluster). Các cụm này đại diện cho các nhóm thành phố có đặc điểm nhiệt độ tương đồng nhau, từ đó hỗ trợ cho việc phân tích và khai thác dữ liệu ở các bước tiếp theo.

Bảng 5.5: Kết quả phân cụm các thành phố (mẫu)

City	Mean	Min	Max	Std	Range	Cluster
Abidjan	29.88	28	32	1.15	4	3
Acapulco	29.42	25	32	2.19	7	3
Accra	30.04	27	32	1.68	5	3
Adak	6.12	4	7	0.99	3	1
Addis Ababa	18.83	15	23	2.72	8	3

5.2.4 Đánh giá mô hình

Kết quả phân cụm với $K = 4$ cho thấy dữ liệu được chia thành các nhóm có đặc điểm nhiệt độ khác nhau.

Cụ thể, cụm 3 bao gồm các thành phố có nhiệt độ trung bình cao, điển hình như Abidjan (29.88°C), Acapulco (29.42°C) và Accra (30.04°C). Nhóm này có nhiệt độ trung bình dao động trong khoảng từ khoảng 28°C đến 31°C, đại diện cho các khu vực có khí hậu nóng, chủ yếu nằm ở vùng nhiệt đới.

Cụm 1 bao gồm các thành phố có nhiệt độ thấp, tiêu biểu là Adak với nhiệt độ trung bình chỉ 6.12°C. Nhìn chung, cụm này có nhiệt độ trung bình dưới 10°C, đại diện cho các khu vực có khí hậu lạnh.

Các cụm còn lại (cụm 0 và cụm 2) đại diện cho các nhóm trung gian:

- Một cụm có nhiệt độ trung bình khoảng từ 10°C đến 20°C, đại diện cho khí hậu mát hoặc ôn đới.
- Một cụm có nhiệt độ trung bình khoảng từ 20°C đến 27°C, đại diện cho khí hậu ấm.

Ví dụ, Addis Ababa có nhiệt độ trung bình 18.83°C, thuộc nhóm nhiệt độ trung bình nhưng có độ biến động lớn (std = 2.72, range = 8), cho thấy yếu tố dao động nhiệt cũng ảnh hưởng đến kết quả phân cụm.

Nhìn chung, các cụm được hình thành có sự phân tách tương đối rõ ràng:

- Cụm nhiệt độ thấp: dưới 10°C
- Cụm nhiệt độ mát: 10–20°C
- Cụm nhiệt độ ấm: 20–27°C
- Cụm nhiệt độ cao: trên 28°C

Kết quả này cho thấy mô hình đã học được cấu trúc hợp lý của dữ liệu và phân nhóm các thành phố phù hợp với đặc điểm khí hậu thực tế.

5.2.5 Trực quan hóa kết quả



Hình 5.1: Trực quan hóa kết quả phâm cụm

Kết quả trực quan hóa dữ liệu thông qua biểu đồ phân tán (scatter plot) cho thấy sự hình thành rõ rệt của 04 cụm (cluster) chính:

- **Cụm màu Xanh đậm (Phía bên trái):** Nhóm này bao gồm các thành phố có nhiệt độ trung bình từ rất thấp (dưới $0°C$) đến khoảng $12°C$ với biên độ nhiệt dao động ở mức trung bình thấp ($0°C - 10°C$). Đây là các khu vực đại diện cho kiểu khí hậu lạnh nhưng tương đối ổn định về nhiệt độ.
- **Cụm màu Xanh nhạt (Phía trên, ở giữa):** Nhóm này chiếm lĩnh vùng có biên độ nhiệt cao nhất (từ $8°C - 21°C$). Đáng chú ý, cụm này duy trì đặc tính biên độ nhiệt lớn ngay cả khi nhiệt độ trung bình tăng từ $0°C$ lên đến $20°C$. Đây là nhóm đại diện cho các khu vực có sự chênh lệch nhiệt độ đáng kể giữa các mùa trong năm hoặc giữa ngày và đêm.
- **Cụm màu Vàng/Tím (Phía dưới, bên phải):** Nhóm này tập trung vào các thành phố có nhiệt độ trung bình cao ($12°C - 35°C$) và biên độ nhiệt thấp ($0°C - 10°C$). Đây là đặc điểm của các vùng khí hậu nóng, ít biến động, thường thấy tại các khu vực địa lý gần xích đạo.
- **Khả năng phân tách:** Thuật toán phân cụm đã phân tách dữ liệu thành các nhóm có ranh giới khá rõ rệt, đặc biệt là sự tách biệt theo trục hoành (nhiệt độ trung bình). Kết quả này cho thấy mối tương quan nghịch giữa nhiệt độ trung bình và biên độ nhiệt trong một số phạm vi dữ liệu nhất định.

5.2.6 Phân tích các cụm

Mục tiêu

- **Định danh nhóm:** Xác định đặc điểm khí hậu đặc trưng của từng cụm dựa trên các chỉ số nhiệt độ đã được tính toán.
- **Giải thích sự phân hóa:** Hiểu rõ tại sao các thành phố lại được nhóm cùng nhau (dựa trên mức độ nóng/lạnh và sự biến thiên nhiệt độ).
- **Kiểm chứng:** Đánh giá tính hợp lý của việc lựa chọn số cụm ($K = 3$) so với thực tế địa lý toàn cầu.

Quy trình thực hiện

- **Bước 1 (Gom nhóm):** Sử dụng các nhãn cụm đã dự đoán để nhóm dữ liệu gốc.
- **Bước 2 (Thống kê):** Tính toán giá trị trung bình (Mean) cho 5 đặc trưng: *mean_temp, min_temp, max_temp, std_temp, range_temp.*
- **Bước 3 (Đối chiếu):** So sánh các giá trị trung bình này giữa các cụm để tìm ra sự khác biệt lớn nhất.
- **Bước 4 (Gán nhãn):** Dựa trên quy luật khí tượng học để đặt tên cho từng cụm.

Bảng: Chỉ số nhiệt độ trung bình của từng cụm

Bảng 5.6: Chỉ số nhiệt độ trung bình theo cụm

Đặc trưng (Trung bình)	**Cụm 0**	**Cụm 1**	**Cụm 2**
Nhiệt độ TB (°C)	-21.65	29.82	16.48
Nhiệt độ thấp nhất (°C)	-26.30	27.20	7.50
Nhiệt độ cao nhất (°C)	-16.80	32.50	26.80
Độ lệch chuẩn nhiệt độ	3.25	1.45	5.80
Biên độ nhiệt (°C)	9.50	5.30	19.30

Dựa trên bảng số liệu trên, đặc điểm của ba cụm được phân tích như sau:

- **Cụm 0: Nhóm khí hậu hàn đới (vùng cực)**
  - **Giải thích:** Cụm này có nhiệt độ trung bình và cực tiểu thấp nhất (đều dưới 0°C). Các thành phố thuộc cụm này thường nằm ở vĩ độ cao, nơi lượng bức xạ mặt trời rất hạn chế.
  - **Đặc điểm:** Lạnh giá quanh năm, biên độ nhiệt không quá lớn nhưng nền nhiệt cực thấp.
  - **Ví dụ:** Alert, Tiksi.
- **Cụm 1: Nhóm khí hậu nhiệt đới**
  - **Giải thích:** Có nhiệt độ trung bình cao nhất (khoảng 30°C), đồng thời có biên độ nhiệt và độ lệch chuẩn thấp nhất, cho thấy nhiệt độ ổn định trong ngày.
  - **Đặc điểm:** Nóng ẩm, ít biến động nhiệt độ.
  - **Ví dụ:** Abidjan, Bangkok, Singapore.

- **Cụm 2: Nhóm khí hậu ôn đới / lục địa**
  - **Giải thích:** Nhiệt độ trung bình ở mức trung bình (16.48°C), nhưng có biên độ nhiệt lớn nhất (19.30°C), thể hiện sự chênh lệch rõ rệt giữa ngày và đêm hoặc giữa các mùa.
  - **Đặc điểm:** Khí hậu biến động mạnh, thường xuất hiện ở khu vực sâu trong lục địa hoặc vùng ôn đới.
  - **Ví dụ:** Tashkent, Almaty, Madrid.

Nhận xét

Kết quả phân cụm đã phản ánh rõ ràng sự phân hóa khí hậu toàn cầu. Thuật toán K-means không chỉ nhóm các thành phố theo cảm tính mà dựa trên cơ sở toán học chặt chẽ về sự tương đồng trong các đặc trưng nhiệt độ. Điều này giúp cung cấp một cái nhìn tổng quan và có hệ thống về các kiểu khí hậu đặc trưng trên thế giới.

5.2.7 So sánh mô hình (From Scratch vs Thư viện)

Mục tiêu

- **Kiểm chứng thuật toán:** Xác nhận tính đúng đắn của mã nguồn tự triển khai (From Scratch) bằng cách đối chiếu kết quả với thư viện chuẩn quốc tế Scikit-learn.
- **Đánh giá hiệu năng:** So sánh tốc độ xử lý và khả năng tối ưu hóa tài nguyên giữa phương pháp thủ công và thư viện chuyên dụng.
- **Độ ổn định:** Xem xét mức độ nhạy cảm của thuật toán đối với việc khởi tạo tâm cụm ban đầu.

Quy trình thực hiện:

- **Bước 1 (Đồng nhất dữ liệu):** Sử dụng cùng một tập dữ liệu đã chuẩn hóa *X_scaled* từ *DATASET_BAITOAN1.csv* cho cả hai mô hình.
- **Bước 2 (Thiết lập tham số):** Cấu hình cùng số cụm $K = 3$ và số lần lặp tối đa *max_iters=100*.
- **Bước 3 (Thực thi và Đo lường):** Sử dụng thư viện *time* để đo thời gian chạy và thư viện *metrics* để tính toán chỉ số Silhouette.
- **Bước 4 (Tính toán Inertia):** Đối với bản tự viết, ta xây dựng hàm tính tổng bình phương khoảng cách từ các điểm đến tâm cụm tương ứng để so sánh với thuộc tính *inertia_* có sẵn của Sklearn.

Bảng 5.7: So sánh hiệu quả giữa K-Means tự viết và Sklearn

Tiêu chí so sánh	K-Means tự triển khai (From Scratch)	Thư viện chuyên dụng (Sklearn)	Nhận xét
Thời gian thực thi	0.07820 giây	0.00350 giây	Sklearn nhanh hơn gấp ∼20 lần
Chỉ số Inertia	458.15	450.23	Sklearn tối ưu hơn nhờ K-Means++
Silhouette Score	0.6415	0.6587	Cả hai đều đạt mức tách biệt tốt (> 0.6)
Độ chính xác nhãn	97.5% (Tương đương)	100% (Chuẩn)	Kết quả phân cụm gần như trùng khớp

- **Về Tốc độ:** Thư viện Sklearn vượt trội hoàn toàn. Lý do là Sklearn được viết trên nền tảng Cython/C++ tối ưu hóa bộ nhớ và các phép toán ma trận song song, trong khi bản From Scratch chạy trên vòng lặp Python thuần nên sẽ chậm dần khi dữ liệu lớn hơn.
- **Về Độ chính xác (Inertia):** Chỉ số Inertia của Sklearn thấp hơn (tốt hơn). Điều này là do Sklearn sử dụng thuật toán K-Means++ để khởi tạo tâm cụm ban đầu (chọn các điểm cách xa nhau), giúp thuật toán tìm được điểm hội tụ tối ưu toàn cục. Bản tự viết khởi tạo ngẫu nhiên nên đôi khi bị rơi vào các vùng dữ liệu cục bộ.
- **Về Độ tách biệt (Silhouette):** Cả hai mô hình đều cho chỉ số Silhouette xấp xỉ nhau ($\sim$0.65). Điều này khẳng định rằng mặc dù bản tự viết chậm hơn, nhưng logic toán học về việc tính khoảng cách Euclidean và cập nhật trọng tâm (Centroid) đã được triển khai hoàn toàn chính xác.

Việc tự triển khai thuật toán giúp người nghiên cứu hiểu rõ bản chất vận hành bên trong của K-Means. Tuy nhiên, trong các bài toán thực tế với dữ liệu lớn, việc sử dụng thư viện Sklearn là lựa chọn tối ưu để đảm bảo sự ổn định, tốc độ và độ chính xác cao nhất cho mô hình.

5.3 Bài toán 2: Dự đoán trạng thái nhiệt độ

Bên cạnh bài toán phân cụm các thành phố theo đặc trưng nhiệt độ, nhóm tiếp tục triển khai bài toán dự đoán trạng thái nhiệt độ bằng phương pháp học có giám sát. Mục tiêu của bài toán này là xây dựng mô hình có khả năng dự đoán mức nhiệt độ của một thành phố dựa trên các thông tin đầu vào thu thập được trong bộ dữ liệu.

Bộ dữ liệu của nhóm được xây dựng từ quá trình thu thập dữ liệu thực tế trên trang Timeanddate, đảm bảo tính thực tiễn và phản ánh đúng điều kiện thời tiết tại các khu vực khác nhau. Dữ liệu bao gồm các thuộc tính chính phục vụ cho bài toán phân tích và dự đoán.

Cụ thể, bộ dữ liệu gồm tên thành phố (`city`), thời gian địa phương (`local_time`), nhiệt độ thực tế (`temperature`) và thời điểm thu thập (`crawl_timestamp`). Các thuộc tính này tạo thành nền tảng dữ liệu quan trọng để phục vụ cho các bước tiền xử lý, phân tích và xây dựng mô hình học máy trong đề tài.

Từ cột nhiệt độ gốc, nhóm tiến hành chuyển đổi sang biến mục tiêu dạng phân loại, gọi là trạng thái nhiệt độ. Việc chuyển đổi này giúp bài toán hồi quy nhiệt độ liên tục trở thành bài toán phân loại nhiều lớp, phù hợp với các mô hình Logistic Regression và Softmax Regression.

Sau quá trình xử lý, dữ liệu được chia thành hai phần chính. Tập huấn luyện được sử dụng để mô hình học các quy luật và mối quan hệ trong dữ liệu, giúp mô hình tối ưu các tham số trong quá trình học.

Trong khi đó, tập kiểm tra được dùng để đánh giá khả năng dự đoán của mô hình trên dữ liệu chưa từng thấy, nhằm kiểm tra mức độ tổng quát hóa. Các đặc trưng đầu vào bao gồm thông tin về thành phố, giờ địa phương và các đặc trưng thời gian được trích xuất từ thời điểm ghi nhận, giúp mô hình khai thác đầy đủ thông tin phục vụ dự đoán.

5.3.1 Mô hình Logistic Regression

Tổng quan mô hình

Logistic Regression là một trong những thuật toán cơ bản và phổ biến nhất trong bài toán phân loại. Mặc dù tên gọi chứa từ "Regression", nhưng bản chất của thuật toán là mô hình phân loại xác suất.

Thuật toán này được sử dụng để dự đoán xác suất một mẫu dữ liệu thuộc về một lớp nhất định dựa trên tổ hợp tuyến tính của các đặc trưng đầu vào. Với bài toán của nhóm, Logistic Regression được sử dụng để dự đoán trạng thái nhiệt độ của từng thành phố.

Lý do lựa chọn Logistic Regression

Nhóm lựa chọn Logistic Regression vì một số lý do chính. Trước hết, đây là mô hình phù hợp với bộ dữ liệu có quy mô vừa phải, giúp đảm bảo hiệu quả trong quá trình huấn luyện mà không yêu cầu tài nguyên quá lớn. Bên cạnh đó, Logistic Regression có tốc độ huấn luyện nhanh, dễ triển khai và dễ giải thích kết quả, phù hợp với mục tiêu nghiên cứu của đề tài.

Ngoài ra, mô hình này hoạt động tốt khi dữ liệu đã được chuẩn hóa và có thể mở rộng sang bài toán nhiều lớp thông qua Softmax Regression. Đây cũng là một mô hình nền tảng quan trọng, được sử dụng để so sánh với mô hình Softmax tự cài đặt từ đầu, giúp đánh giá rõ hơn sự khác biệt giữa phương pháp thư viện và tự xây dựng.

Nguyên lý hoạt động

Logistic Regression xây dựng mối liên hệ giữa đầu vào và xác suất đầu ra thông qua hàm sigmoid đối với phân loại nhị phân hoặc hàm softmax đối với phân loại nhiều lớp.

Mô hình học các trọng số tương ứng với từng đặc trưng. Khi một đặc trưng có ảnh hưởng lớn đến trạng thái nhiệt độ, hệ số tương ứng sẽ có giá trị lớn hơn.

Trong đề tài này, do trạng thái nhiệt độ được chia thành nhiều mức, nhóm sử dụng Logistic Regression đa lớp để dự đoán nhãn nhiệt độ.

Quy trình huấn luyện

Quá trình huấn luyện mô hình được thực hiện theo các bước tuần tự. Đầu tiên, dữ liệu đầu vào sau khi đã được chuẩn hóa được đưa vào mô hình để đảm bảo tính đồng nhất và ổn định trong tính toán. Tiếp theo, mô hình tiến hành tính toán xác suất dự đoán cho từng mẫu dữ liệu và so sánh kết quả với nhãn thực tế để xác định sai số. Dựa trên sai số này, hàm mất mát được tối ưu hóa thông qua Gradient Descent hoặc các bộ tối ưu có sẵn trong thư viện. Quá trình cập nhật trọng số được lặp lại nhiều lần cho đến khi mô hình đạt trạng thái hội tụ, tức là sai số không còn giảm đáng kể qua các vòng lặp tiếp theo.

Vai trò trong đề tài

Logistic Regression được sử dụng như một mô hình chuẩn trong bài toán nhằm đánh giá hiệu quả dự đoán trạng thái nhiệt độ. Thông qua mô hình này, nhóm có thể kiểm tra mức độ chính xác của việc phân loại và khả năng hoạt động trên dữ liệu thực tế. Ngoài ra, mô hình còn được dùng để so sánh với phiên bản Softmax tự xây dựng từ đầu, từ đó đánh giá sự khác biệt giữa cách tiếp cận sử dụng thư viện và tự triển khai. Logistic Regression cũng đóng vai trò là cơ sở để phân tích mức độ ảnh hưởng của các đặc trưng đầu vào, đồng thời giúp kiểm tra tốc độ hội tụ và độ ổn định trong quá trình huấn luyện.

5.3.2 Triển khai Softmax từ đầu

GIỚI THIỆU BÀI TOÁN

Mô tả

Bài toán đặt ra là dự đoán trạng thái nhiệt độ tại thời điểm $t+1$ dựa trên các thông tin quan sát được tại thời điểm t. Cụ thể, đầu vào của mô hình bao gồm nhiệt độ hiện tại, xu hướng thay đổi nhiệt độ và thời gian trong ngày. Đây là một bài toán phân loại đa lớp với bốn nhãn chính: *cold*, *cool*, *warm* và *hot*.

Mô hình được xây dựng dựa trên phương pháp Softmax Regression và được triển khai từ đầu nhằm làm rõ cơ chế hoạt động của thuật toán.

Dữ liệu đầu vào

Tập dữ liệu gồm 9.211 mẫu, được thu thập từ nhiều thành phố theo từng giờ. Các thuộc tính phản ánh trạng thái nhiệt độ và đặc điểm chu kỳ theo thời gian.

Bảng 5.8: Các cột trong tập dữ liệu

Tên cột	Kiểu	Ý nghĩa
local_hour_24	int	Giờ trong ngày (0–23)
temperature	int	Nhiệt độ tại thời điểm t ($^\circ C$)
delta_temp	float	Mức thay đổi nhiệt độ
hour_sin	float	Biểu diễn chu kỳ giờ (sin)
hour_cos	float	Biểu diễn chu kỳ giờ (cos)
label	str	Nhãn tại thời điểm $t+1$

Phân phối nhãn

Phân phối dữ liệu cho thấy sự mất cân bằng giữa các lớp, trong đó lớp *cold* chiếm tỷ lệ lớn nhất, trong khi lớp *hot* chiếm tỷ lệ nhỏ nhất. Điều này có thể ảnh hưởng đến khả năng học của mô hình nếu không có biện pháp xử lý phù hợp.

Bảng 5.9: Phân phối nhãn

Nhãn	Số mẫu	Tỷ lệ (%)
cold	3547	38.5
warm	2838	30.8
cool	1814	19.7
hot	1012	11.0
Tổng	9211	100.0

XÂY DỰNG ĐẶC TRƯNG

Phân tích dữ liệu

Phân tích dữ liệu cho thấy tồn tại sự chồng lấn đáng kể giữa các nhãn theo giá trị nhiệt độ. Hai vùng gây nhầm lẫn chính được xác định là khoảng $26^{\smile}32°C$ (giữa *warm* và *hot*) và $11^{\smile}17°C$ (giữa *cold* và *cool*). Đây là nguyên nhân chính dẫn đến sai số của mô hình nếu chỉ sử dụng các đặc trưng tuyến tính đơn giản.

Bảng 5.10: Phạm vi nhiệt độ

Nhãn	Min	Max	Mean
cold	-32	21	4.1
cool	6	26	17.9
warm	12	36	25.7
hot	21	43	31.8

Nhóm đặc trưng

Để cải thiện khả năng phân loại, hệ thống đặc trưng được mở rộng theo nhiều hướng khác nhau. Các đặc trưng phi tuyến được sử dụng nhằm mô tả mối quan hệ bậc cao giữa nhiệt độ và nhãn. Bên cạnh đó, các đặc trưng phân vùng giúp chia không gian nhiệt độ thành các khoảng cơ bản, hỗ trợ mô hình xác định ranh giới ban đầu. Đặc biệt, các đặc trưng vùng biên được thiết kế để xử lý trực tiếp các khu vực có sự chồng lấn, trong khi các đặc trưng tương tác giúp kết hợp thông tin giữa nhiệt độ, thời gian và xu hướng thay đổi.

Tổng hợp đặc trưng

Sau quá trình xây dựng, mô hình sử dụng tổng cộng 23 đặc trưng, được chia thành bốn nhóm chính như sau:

Bảng 5.11: Danh sách đặc trưng chi tiết

Nhóm	**Tên đặc trưng**	**Ý nghĩa**
Gốc (4)	temperature, delta_temp, hour_sin, hour_cos	Dữ liệu thô từ dataset
Phi tuyến (6)	temp_squared, temp_cubed, temp_abs, temp_x_delta, temp_x_hour, delta_squared	Mô tả các quan hệ bậc cao giữa các biến
Bin (4)	temp_bin_cold, temp_bin_cool, temp_bin_warm, temp_bin_hot	Phân chia nhiệt độ thành bốn vùng cơ bản
Biên (9)	dist_to_28, dist_to_14, in_wh_zone, in_cc_zone, delta_in_wh, delta_in_cc, hour_in_wh, hour_in_cc, temp_delta_sq	Tập trung xử lý các vùng có sự chồng lấn giữa các lớp

CHUẨN HÓA VÀ CHIA TẬP

Chuẩn hóa

Các đặc trưng được chuẩn hóa về cùng thang đo nhằm đảm bảo quá trình huấn luyện ổn định và tránh việc các đặc trưng có giá trị lớn chi phối mô hình.

Chia tập dữ liệu

Dữ liệu được chia thành hai phần: 80% cho huấn luyện và 20% cho kiểm tra. Việc chia dữ liệu sử dụng kỹ thuật stratified sampling nhằm giữ nguyên phân phối nhãn giữa các tập.

TRỌNG SỐ MẪU

Trọng số lớp

Do dữ liệu mất cân bằng, mỗi lớp được gán một trọng số khác nhau nhằm tăng ảnh hưởng của các lớp thiểu số trong quá trình huấn luyện.

Bảng 5.12: Trọng số lớp

Nhãn	Trọng số	Ý nghĩa
cold	0.649	Lớp đa số
cool	1.269	Trung bình
hot	2.275	Thiểu số
warm	0.811	Trung bình

Boundary Boost

Bên cạnh trọng số lớp, các mẫu nằm trong vùng dễ nhầm lẫn cũng được tăng trọng số nhằm giúp mô hình tập trung học tốt hơn tại các khu vực khó phân loại.

MÔ HÌNH

Softmax Regression

Mô hình sử dụng hàm Softmax để chuyển đổi đầu ra tuyến tính thành phân phối xác suất trên các lớp. Để đảm bảo ổn định số học, giá trị lớn nhất của vector logit được trừ đi trước khi tính toán hàm mũ.

Hàm mất mát

Hàm mất mát được định nghĩa như sau:

$$L = -\frac{1}{N}\sum_{i} s_i \sum_{c} y_{ic} \log(\hat{p}_{ic} + \varepsilon) + \lambda \|W\|_F^2$$

Hàm này kết hợp giữa Cross-Entropy có trọng số và chuẩn hóa L2, trong đó trọng số mẫu giúp tăng ảnh hưởng của các mẫu quan trọng, còn thành phần L2 giúp hạn chế hiện tượng overfitting.

Tối ưu

Quá trình huấn luyện sử dụng thuật toán Adam để cập nhật tham số. Phương pháp này tận dụng trung bình trượt của gradient và bình phương gradient, từ đó điều chỉnh tốc độ học một cách thích nghi, giúp mô hình hội tụ nhanh và ổn định.

Bảng 5.13: Siêu tham số của mô hình

Siêu tham số	Giá trị	Ý nghĩa
Learning rate	0.001	Tốc độ học
Epochs	2500	Số vòng lặp
λ	0.001	Regularization
β_1	0.9	Moment bậc 1
β_2	0.999	Moment bậc 2

KẾT LUẬN

Mô hình đạt hiệu suất tốt với độ chính xác 90.45%. Việc kết hợp giữa xây dựng đặc trưng, xử lý mất cân bằng dữ liệu và tối ưu tham số đã giúp cải thiện đáng kể hiệu quả so với phiên bản ban đầu.

5.3.3 Sử dụng thư viện

Xây dựng và so sánh mô hình phân loại

Quy trình thực hiện

Quy trình xây dựng mô hình được thực hiện theo các bước sau:

1. Thu thập và đọc dữ liệu từ file CSV.
2. Tiền xử lý và xây dựng các đặc trưng mới (feature engineering).
3. Chuẩn hóa dữ liệu đầu vào.
4. Chia dữ liệu thành tập huấn luyện và tập kiểm tra.
5. Huấn luyện hai mô hình: Logistic Regression và Random Forest.
6. Đánh giá mô hình bằng các chỉ số như Accuracy, Precision, Recall, F1-score và Confusion Matrix.

Tiền xử lý và xây dựng đặc trưng

Dữ liệu ban đầu bao gồm các biến như nhiệt độ (*temperature*), độ thay đổi nhiệt độ (*delta_ temp*) và thời gian trong ngày.

Để cải thiện khả năng phân loại, các đặc trưng mới được xây dựng bao gồm:

- Đặc trưng phi tuyến: $temperature^2$, $temperature^3$
- Đặc trưng tương tác: $temperature \times delta_temp$
- Phân vùng nhiệt độ (cold, cool, warm, hot)
- Đặc trưng khoảng cách đến ranh giới: $|temperature - 28|$, $|temperature - 14|$
- Đặc trưng vùng nhạy (boundary features) nhằm tăng khả năng phân biệt tại các vùng dễ nhầm lẫn

Các đặc trưng này giúp mô hình nắm bắt tốt hơn mối quan hệ phi tuyến giữa các biến.

Chuẩn hóa dữ liệu

Đối với mô hình Logistic Regression, dữ liệu được chuẩn hóa bằng phương pháp StandardScaler nhằm đưa các đặc trưng về cùng một thang đo:

$$X_{scaled} = \frac{X - \mu}{\sigma}$$

Việc chuẩn hóa giúp quá trình tối ưu hội tụ nhanh hơn và ổn định hơn.

Đối với Random Forest, việc chuẩn hóa không bắt buộc, tuy nhiên vẫn được giữ để đảm bảo tính nhất quán giữa hai mô hình.

Mục tiêu mô hình

Hai mô hình được sử dụng với mục tiêu như sau:

- **Logistic Regression**: Mô hình tuyến tính sử dụng hàm Softmax để phân loại đa lớp.
- **Random Forest**: Mô hình phi tuyến dựa trên tập hợp nhiều cây quyết định nhằm cải thiện khả năng học các quan hệ phức tạp.

Việc so sánh hai mô hình giúp đánh giá liệu bài toán có tính tuyến tính hay phi tuyến.

Kết quả mô hình Random Forest

- Accuracy: 91.21%

Bảng 5.14: Classification Report - Random Forest

Class	Precision	Recall	F1-score	Support
cold	0.97	0.95	0.96	710
cool	0.84	0.89	0.87	363
hot	0.79	0.95	0.86	202
warm	0.94	0.87	0.90	568
Accuracy		0.91		
Macro Avg	0.89	0.91	0.90	1843
Weighted Avg	0.92	0.91	0.91	1843

Kết quả mô hình Logistic Regression

- Accuracy: 92.00%

Bảng 5.15: Classification Report - Logistic Regression

Class	Precision	Recall	F1-score	Support
cold	0.97	0.97	0.97	710
cool	0.87	0.88	0.88	363
hot	0.82	0.92	0.87	202
warm	0.93	0.89	0.91	568
Accuracy		0.92		
Macro Avg	0.90	0.91	0.91	1843
Weighted Avg	0.92	0.92	0.92	1843

Nhận xét

Kết quả cho thấy cả hai mô hình đều đạt hiệu suất cao, với độ chính xác trên 91%.

Một số nhận xét quan trọng:

- Logistic Regression cho kết quả tốt hơn nhẹ so với Random Forest về cả Accuracy và F1-score.

- Lớp **cold** được phân loại rất tốt trong cả hai mô hình do nằm xa các lớp khác.
- Sai số chủ yếu tập trung tại ranh giới giữa các lớp **warm** và **hot**, cho thấy sự chồng lấn trong dữ liệu.
- Random Forest có xu hướng dự đoán dư lớp **hot**, dẫn đến precision thấp hơn.

So sánh hai mô hình

Bảng 5.16: So sánh hiệu suất hai mô hình

Model	Accuracy	Macro F1	Weighted F1
Random Forest	0.91	0.90	0.91
Logistic Regression	0.92	0.91	0.92

Kết luận

Mặc dù Random Forest là mô hình phi tuyến mạnh, Logistic Regression lại cho kết quả tốt hơn trong bài toán này. Điều này cho thấy:

- Tập đặc trưng đã được thiết kế hiệu quả, giúp mô hình tuyến tính hoạt động tốt.
- Bài toán sau khi feature engineering trở nên gần tuyến tính.
- Sai số chủ yếu đến từ bản chất dữ liệu thay vì hạn chế của mô hình.

5.3.4 Phân tích đặc trưng

Ý nghĩa của phân tích đặc trưng

Phân tích đặc trưng là bước quan trọng giúp xác định mức độ ảnh hưởng của từng biến đầu vào đến kết quả dự đoán. Không phải tất cả các thuộc tính trong dữ liệu đều có vai trò như nhau. Một số biến mang nhiều thông tin hơn và đóng góp mạnh vào quyết định của mô hình.

Thông qua phân tích đặc trưng, nhóm có thể hiểu rõ hơn về cách mô hình học từ dữ liệu và xác định được những yếu tố nào thực sự đóng vai trò quan trọng trong quá trình dự đoán. Điều này giúp làm rõ cơ chế hoạt động bên trong của mô hình, thay vì chỉ nhìn vào kết quả đầu ra. Bên cạnh đó, việc phân tích đặc trưng còn cho phép loại bỏ những biến ít quan trọng hoặc không mang nhiều thông tin, từ đó giúp giảm độ phức tạp của mô hình và hạn chế nhiễu trong quá trình huấn luyện. Nhờ vậy, hiệu suất tổng thể của mô hình cũng được cải thiện đáng kể, cả về tốc độ lẫn độ chính xác. Ngoài ra, quá trình này còn giúp tăng khả năng giải thích kết quả dự đoán, giúp người thực hiện có thể lý giải được vì sao mô hình đưa ra một kết quả cụ thể. Điều này đặc biệt quan trọng trong các bài toán thực tế, nơi tính minh bạch và khả năng giải thích của mô hình được đặt lên hàng đầu.

Các đặc trưng sử dụng trong bài toán

Dựa trên bộ dữ liệu thu thập được, nhóm lựa chọn các đặc trưng chính để phục vụ cho quá trình huấn luyện và phân tích mô hình. Cụ thể, bao gồm thông tin về thành phố (`city`), giúp phản ánh sự khác biệt về điều kiện khí hậu giữa các khu vực.

Bên cạnh đó, giờ địa phương (`local_hour_24`) được sử dụng để khai thác sự biến động nhiệt độ theo từng khung thời gian trong ngày. Ngoài ra, các đặc trưng thời gian được tách từ `crawl_timestamp` cũng được đưa vào nhằm cung cấp thêm thông tin chi tiết về thời điểm ghi nhận dữ liệu.

Trong một số trường hợp, các biến thời gian còn được mã hóa thêm nếu cần thiết để phù hợp với mô hình học máy, giúp tăng khả năng biểu diễn và cải thiện hiệu quả dự đoán.

Phân tích ảnh hưởng của từng đặc trưng

5.3.5 Phân tích đặc trưng (Feature Analysis)

Nhóm đặc trưng gốc

Tên đặc trưng	Ý nghĩa
temperature	Nhiệt độ tại thời điểm quan sát
delta_temp	Độ thay đổi nhiệt độ
hour_sin	Biểu diễn chu kỳ thời gian (sin)
hour_cos	Biểu diễn chu kỳ thời gian (cos)

Bảng 5.17: Nhóm đặc trưng gốc

Nhóm đặc trưng gốc cung cấp thông tin nền tảng của dữ liệu. Trong đó, *temperature* là biến quan trọng nhất vì trực tiếp quyết định nhãn phân loại. Biến *delta_temp* bổ sung thông tin về xu hướng thay đổi nhiệt độ, giúp mô hình phân biệt các trường hợp có cùng mức nhiệt nhưng khác về chiều hướng biến động. Hai biến *hour_sin* và *hour_cos* được sử dụng để biểu diễn thời gian theo dạng tuần hoàn, cho phép mô hình học được quy luật biến thiên nhiệt độ theo chu kỳ ngày đêm.

Nhóm đặc trưng phi tuyến

Tên đặc trưng	Ý nghĩa
temp_squared	Bình phương nhiệt độ
temp_cubed	Lập phương nhiệt độ
temp_abs	Giá trị tuyệt đối của nhiệt độ
temp_x_delta	Tương tác nhiệt độ và độ thay đổi
temp_x_hour	Tương tác nhiệt độ và thời gian
delta_squared	Bình phương độ thay đổi nhiệt độ

Bảng 5.18: Nhóm đặc trưng phi tuyến

Nhóm đặc trưng phi tuyến giúp mô hình nắm bắt các quan hệ bậc cao và các dạng biến thiên không tuyến tính trong dữ liệu. Các biến như *temp_squared* và *temp_cubed* cho phép mô hình xấp xỉ các ranh giới phân lớp dạng cong, trong khi các đặc trưng tương tác như *temp_x_delta* và *temp_x_hour* giúp mô hình xét đến ảnh hưởng kết hợp giữa nhiệt độ với các yếu tố khác. Điều này làm tăng khả năng phân biệt trong các trường hợp phức tạp.

Nhóm đặc trưng phân vùng (Bin)

Tên đặc trưng	Ý nghĩa
temp_bin_cold	Nhiệt độ thấp
temp_bin_cool	Nhiệt độ trung bình thấp
temp_bin_warm	Nhiệt độ trung bình cao
temp_bin_hot	Nhiệt độ cao

Bảng 5.19: Nhóm đặc trưng phân vùng

Nhóm đặc trưng phân vùng chuyển đổi biến nhiệt độ liên tục thành các biến rời rạc tương ứng với từng lớp. Điều này giúp mô hình nhanh chóng xác định một quan sát thuộc khoảng nhiệt độ nào, từ đó hỗ trợ quá trình phân loại. Đối với các mô hình tuyến tính, các biến này đóng vai trò như các ngưỡng phân tách rõ ràng, giúp cải thiện hiệu quả dự đoán.

Nhóm đặc trưng ranh giới (Boundary)

Tên đặc trưng	Ý nghĩa
dist_to_28	Khoảng cách đến ngưỡng warm/hot
dist_to_14	Khoảng cách đến ngưỡng cold/cool
in_wh_zone	Vùng dễ nhầm warm-hot
in_cc_zone	Vùng dễ nhầm cold-cool
delta_in_wh	Delta trong vùng warm-hot
delta_in_cc	Delta trong vùng cold-cool
hour_in_wh	Thời gian trong vùng warm-hot
hour_in_cc	Thời gian trong vùng cold-cool
temp_delta_sq	Kết hợp nhiệt độ và delta bình phương

Bảng 5.20: Nhóm đặc trưng ranh giới

Nhóm đặc trưng ranh giới đóng vai trò quan trọng nhất trong việc cải thiện hiệu suất mô hình. Các đặc trưng này tập trung vào những vùng có tỷ lệ nhầm lẫn cao giữa các lớp, đặc biệt là giữa warm và hot. Các biến khoảng cách như *dist_to_28* và *dist_to_14* giúp mô hình xác định mức độ gần ranh giới, trong khi các biến vùng như *in_wh_zone* và *in_cc_zone* cho phép nhận diện trực tiếp các khu vực nhạy cảm. Khi kết hợp với các đặc trưng tương tác, mô hình có thể học sâu hơn về hành vi dữ liệu tại các vùng này, từ đó giảm đáng kể sai số phân loại.

Tổng kết

Tổng thể, bốn nhóm đặc trưng được xây dựng theo hướng bổ trợ lẫn nhau, từ thông tin cơ bản đến các đặc trưng nâng cao và đặc biệt là các yếu tố tập trung vào ranh giới phân lớp. Nhờ đó, không gian đặc trưng trở nên giàu thông tin hơn, giúp mô hình phân tách các lớp hiệu quả. Điều này giải thích vì sao các mô hình tuyến tính như Logistic Regression vẫn có thể đạt hiệu suất cao trong bài toán này.

5.3.6 Phân tích hội tụ

Khái niệm hội tụ

Hội tụ là quá trình mô hình dần tìm được bộ tham số tối ưu trong quá trình huấn luyện. Khi số vòng lặp tăng lên, hàm mất mát giảm dần và các trọng số ổn định, mô hình được xem là đã hội tụ.

Đây là những chỉ tiêu quan trọng giúp đánh giá toàn diện quá trình huấn luyện mô hình. Trước hết, chúng phản ánh tính ổn định của thuật toán trong quá trình cập nhật trọng số, cho thấy mô hình có hội tụ một cách nhất quán hay không. Bên cạnh đó, các chỉ tiêu này còn thể hiện tốc độ học của mô hình, tức là khả năng đạt được kết quả tốt trong bao nhiêu vòng lặp huấn luyện. Đồng thời, chúng cũng phản ánh chất lượng của quá trình tối ưu hóa, giúp đánh giá mức độ hiệu quả khi mô hình giảm hàm mất mát và tiến tới điểm hội tụ.

Quá trình hội tụ của Logistic Regression

Trong quá trình huấn luyện, Logistic Regression tối ưu hàm mất mát bằng các thuật toán tối ưu như Gradient Descent hoặc LBFGS trong thư viện Scikit-learn.

Ban đầu, các trọng số của mô hình thường được khởi tạo ngẫu nhiên hoặc gán bằng 0, do đó khả năng dự đoán còn chưa chính xác. Ở giai đoạn này, sai số giữa giá trị dự đoán và giá trị thực tế thường khá lớn.

Sau mỗi vòng lặp huấn luyện, mô hình tiến hành cập nhật trọng số theo hướng giảm thiểu hàm mất mát, giúp sai số giảm dần theo thời gian. Nhờ quá trình tối ưu liên tục, các tham số dần được điều chỉnh về giá trị phù hợp hơn.

Kết quả là xác suất dự đoán ngày càng chính xác, và mô hình dần hội tụ về trạng thái ổn định, phản ánh đúng hơn mối quan hệ giữa các đặc trưng đầu vào và kết quả đầu ra.

Dấu hiệu mô hình hội tụ tốt

Mô hình được xem là hội tụ tốt khi quá trình tối ưu diễn ra ổn định và đạt được sự cân bằng giữa hiệu quả học và khả năng tổng quát hóa. Cụ thể, ở giai đoạn đầu, hàm loss giảm nhanh cho thấy mô hình đang học được các đặc trưng quan trọng từ dữ liệu.

Sau đó, loss giảm chậm dần về cuối, thể hiện mô hình đang tiến gần đến điểm tối ưu và không còn thay đổi lớn trong các lần cập nhật trọng số. Đồng thời, độ chính xác (accuracy) tăng lên và duy trì ổn định qua các vòng lặp, cho thấy mô hình đã học tốt.

Ngoài ra, sự chênh lệch giữa kết quả trên tập huấn luyện và tập kiểm tra không quá lớn cũng là một dấu hiệu quan trọng, chứng tỏ mô hình không bị overfitting và có khả năng tổng quát hóa tốt trên dữ liệu mới.

Các yếu tố ảnh hưởng đến hội tụ

a. Chuẩn hóa dữ liệu

Nếu dữ liệu không được scale, các đặc trưng chênh lệch lớn sẽ làm quá trình tối ưu chậm và dao động mạnh. Việc sử dụng StandardScaler giúp mô hình hội tụ nhanh hơn.

b. Learning rate

Nếu tốc độ học (learning rate) được thiết lập quá lớn, mô hình có thể cập nhật trọng số quá mạnh sau mỗi vòng lặp, dẫn đến hàm loss dao động liên tục và không ổn định. Trong trường hợp này, mô hình thường gặp khó khăn trong việc hội tụ và có thể không đạt được nghiệm tối ưu.

Ngược lại, nếu tốc độ học quá nhỏ, quá trình cập nhật trọng số diễn ra rất chậm,

khiến thời gian huấn luyện kéo dài đáng kể. Mặc dù mô hình có thể hội tụ ổn định hơn, nhưng hiệu suất học kém và tốn nhiều tài nguyên tính toán hơn. Vì vậy, việc lựa chọn learning rate phù hợp là yếu tố quan trọng để đảm bảo cân bằng giữa tốc độ và độ chính xác của mô hình.

c. Số vòng lặp

Số vòng lặp quá ít khiến mô hình chưa học đủ. Số vòng lặp hợp lý giúp mô hình đạt trạng thái ổn định.

d. Chất lượng dữ liệu

Dữ liệu nhiễu hoặc đặc trưng yếu sẽ làm mô hình khó tìm quy luật.

Nhận xét trong đề tài

Với dữ liệu đã được tiền xử lý và chuẩn hóa tốt, Logistic Regression cho thấy khả năng hội tụ ổn định và thời gian huấn luyện nhanh. Điều này là một ưu điểm quan trọng khi làm việc với bộ dữ liệu có quy mô trung bình như trong bài toán của nhóm, giúp quá trình xây dựng mô hình trở nên hiệu quả hơn. Kết quả thực nghiệm cho thấy mô hình dễ huấn luyện, hoạt động ổn định và cho ra các dự đoán có độ tin cậy cao. Nhờ đó, Logistic Regression không chỉ đáp ứng tốt yêu cầu phân loại mà còn đảm bảo tính nhất quán trong quá trình huấn luyện. Đồng thời, mô hình này cũng phù hợp để đóng vai trò là mô hình nền tảng, phục vụ việc so sánh với Softmax Regression tự cài đặt từ đầu nhằm đánh giá sự khác biệt giữa các phương pháp tiếp cận.

5.3.7 So sánh code tay và thư viện

5.3.8 So sánh tổng quan các mô hình

Bảng 5.21: So sánh hiệu suất các mô hình

Mô hình	Accuracy	Macro F1	Weighted F1	Nhận xét chính
Softmax (tự triển khai)	0.90	0.89	0.91	Dự đoán dư lớp hot
Logistic Regression	0.92	0.91	0.92	Cân bằng tốt nhất
Random Forest	0.91	0.90	0.91	Bắt phi tuyến

Bảng trên cho thấy sự khác biệt tổng quan giữa ba mô hình. Logistic Regression đạt hiệu suất cao nhất với độ chính xác khoảng 92%, đồng thời có Macro F1 và Weighted F1 cao nhất. Diều này cho thấy mô hình không chỉ dự đoán tốt trên tổng thể mà còn duy trì được sự cân bằng giữa các lớp.

Mô hình Softmax tự triển khai đạt độ chính xác khoảng 90%, thấp hơn nhẹ so với hai mô hình còn lại. Tuy nhiên, kết quả này vẫn được xem là tốt, cho thấy việc cài đặt thuật toán là chính xác. Điểm hạn chế của mô hình nằm ở việc dự đoán dư lớp *hot*, dẫn đến precision thấp hơn ở lớp này và kéo giảm F1-score tổng thể.

Random Forest đạt kết quả trung gian với độ chính xác khoảng 91%. Mặc dù đây là mô hình phi tuyến có khả năng học các quan hệ phức tạp, nhưng trong trường hợp này, hiệu suất không vượt trội so với Logistic Regression. Điều này cho thấy các đặc trưng đầu vào đã được xây dựng tốt, giúp bài toán trở nên gần tuyến tính hơn.

Từ kết quả so sánh, có thể thấy rằng chất lượng của tập đặc trưng đóng vai trò quan trọng hơn so với việc lựa chọn mô hình phức tạp. Logistic Regression hoạt động hiệu quả

nhất không phải vì bản thân mô hình mạnh hơn, mà do không gian đặc trưng đã được thiết kế phù hợp với dạng tuyến tính của nó.

Chương 6

Kết quả và thảo luận

6.1 Kết quả phân cụm

Quá trình triển khai thuật toán K-Means trên tập dữ liệu `DATASET_BAITOAN1.csv` đã mang lại cái nhìn sâu sắc về cấu trúc khí hậu của các thành phố trên thế giới. Dựa trên biểu đồ Elbow và chỉ số Silhouette, số cụm $K = 3$ được xác định là giá trị tối ưu, giúp phân tách dữ liệu thành ba nhóm có đặc tính nhiệt độ tách biệt hoàn toàn.

Khi quan sát biểu đồ phân tán giữa nhiệt độ trung bình (*mean_temp*) và biên độ nhiệt (*range_temp*), có thể thấy sự hình thành rõ rệt của các nhóm: cụm 0 tập trung ở phía cực trái của trục hoành (lạnh giá), cụm 1 tập trung ở phía cực phải (nhiệt đới) và cụm 2 nằm ở khoảng giữa với sự phân tán theo trục tung (ôn đới có biến động nhiệt lớn).

Bảng 6.1: Thống kê chi tiết các chỉ số trung bình theo từng cụm

Đặc trưng	**Cụm 0 (Hàn đới)**	**Cụm 1 (Nhiệt đới)**	**Cụm 2 (Ôn đới)**
Nhiệt độ TB	-21.4°C	29.6°C	15.8°C
Nhiệt độ Min	-26.1°C	27.4°C	7.2°C
Biên độ nhiệt	9.2°C	4.8°C	18.5°C
Thành phố ví dụ	Alert, Tiksi	Abidjan, Bangkok	Madrid, Almaty

Phân tích: Cụm 1 (Nhiệt đới) thể hiện tính ổn định cao nhất với biên độ nhiệt chỉ khoảng 4.8°C, cho thấy sự chênh lệch ngày đêm tại các vùng này là rất thấp. Ngược lại, cụm 2 (Ôn đới) cho thấy sự khắc nghiệt của thời tiết với biên độ nhiệt lên tới 18.5°C, phản ánh rõ nét đặc điểm của các thành phố nằm sâu trong lục địa.

6.2 Kết quả phân loại

6.3 Kết luận

Bài toán phân loại nhiệt độ đã được giải quyết thông qua việc kết hợp giữa xây dựng đặc trưng có chủ đích và thử nghiệm nhiều mô hình khác nhau. Kết quả thực nghiệm cho thấy cả ba mô hình, bao gồm Softmax tự triển khai, Logistic Regression và Random Forest, đều đạt hiệu suất cao với độ chính xác dao động từ 90% đến 92%.

Trong đó, Logistic Regression cho kết quả tốt nhất và ổn định nhất trên hầu hết các chỉ số đánh giá. Điều này cho thấy rằng sau quá trình xây dựng đặc trưng, không gian

dữ liệu đã trở nên gần tuyến tính, giúp các mô hình đơn giản vẫn có thể hoạt động hiệu quả. Ngược lại, Random Forest, dù là mô hình phi tuyến mạnh, không mang lại sự cải thiện rõ rệt, cho thấy độ phức tạp của mô hình không phải là yếu tố quyết định trong trường hợp này.

Mô hình Softmax tự triển khai đạt hiệu suất tiệm cận với Logistic Regression, qua đó xác nhận tính đúng đắn của quá trình cài đặt. Tuy vẫn tồn tại một số hạn chế như xu hướng dự đoán dư lớp *hot*, kết quả tổng thể vẫn cho thấy mô hình đã học được các quy luật chính của dữ liệu.

Phân tích chi tiết cho thấy sai số của các mô hình chủ yếu tập trung tại ranh giới giữa các lớp, đặc biệt là giữa *warm* và *hot*. Đây là khu vực có sự chồng lấn tự nhiên trong dữ liệu, khiến việc phân loại trở nên khó khăn ngay cả với các mô hình phức tạp. Tuy nhiên, việc bổ sung các đặc trưng ranh giới đã giúp giảm đáng kể mức độ nhầm lẫn này.

Từ những kết quả đạt được, có thể kết luận rằng yếu tố quan trọng nhất trong bài toán không nằm ở việc lựa chọn mô hình mà nằm ở quá trình xây dựng đặc trưng. Một tập đặc trưng tốt có thể làm giảm đáng kể độ phức tạp của bài toán, cho phép các mô hình đơn giản đạt hiệu suất cao và ổn định. Điều này nhấn mạnh vai trò trung tâm của feature engineering trong các bài toán học máy thực tế.

6.4 Ưu điểm

Hệ thống đã chứng minh được tính khả thi cao trong việc giám sát khí hậu tự động. Một ưu điểm nổi bật là sự kết hợp giữa *Web Scraping* thời gian thực và *Học máy*. Thay vì sử dụng các bộ dữ liệu tĩnh, việc thu thập từ *Time and Date* giúp mô hình luôn được cập nhật với những biến động thực tế của sự nóng lên toàn cầu.

Bên cạnh đó, việc so sánh giữa "code tay" và "thư viện" trong đồ án này mang lại giá trị học thuật lớn. Mặc dù thư viện *Sklearn* cho tốc độ nhanh hơn (0.003s so với 0.08s), nhưng việc tự triển khai *Gradient Descent* đã giúp hiểu rõ cách các trọng số (w) được điều chỉnh để tối thiểu hóa hàm mất mát. Điều này khẳng định hệ thống không chỉ là một công cụ thực dụng mà còn là một cấu trúc có nền tảng toán học vững chắc.

6.5 Hạn chế

Bên cạnh những kết quả đạt được, vẫn còn một số hạn chế cần nhìn nhận:

- **Hạn chế về nguồn dữ liệu**: Việc cào dữ liệu trực tiếp từ website phụ thuộc hoàn toàn vào cấu trúc HTML của trang đó. Nếu website thay đổi giao diện hoặc cơ chế bảo mật (Captcha), hệ thống cần phải được bảo trì và cập nhật mã nguồn cào.
- **Phạm vi đặc trưng**: Hiện tại hệ thống mới chỉ tập trung vào nhiệt độ. Trong thực tế, trạng thái "Cool" hay "Warm" còn phụ thuộc vào các yếu tố khác như độ ẩm, tốc độ gió và áp suất khí quyển.
- **Sự mất cân bằng vùng miền:** : Dữ liệu có thể bị lệch về phía các thành phố lớn do nguồn tin từ website tập trung vào các khu vực này, dẫn đến các vùng thưa dân cư hoặc vùng sâu vùng xa chưa được đại diện đầy đủ trong mô hình.

Hướng phát triển:

- Mở rộng hệ thống để thu thập thêm các biến môi trường khác (độ ẩm, chỉ số UV).
- Thử nghiệm với các mô hình học sâu (*Deep Learning*) như *LSTM* để dự báo nhiệt độ theo chuỗi thời gian (*Time-series forecasting*) dài hạn hơn.
- Xây dựng giao diện *Dashboard* trực quan hóa dữ liệu theo thời gian thực để người dùng dễ dàng theo dõi.

Chương 7

Kết luận

7.1 Tóm tắt

Báo cáo tập trung nghiên cứu quy trình phân tích và khai thác dữ liệu nhiệt độ thời gian thực từ hơn 400 thành phố trên toàn cầu, được thu thập thông qua kỹ thuật Web Scraping tự động. Nghiên cứu giải quyết hai bài toán cốt lõi trong lĩnh vực học máy:

- **Bài toán phân cụm (Unsupervised Learning):** Sử dụng thuật toán K-Means để nhóm các thành phố có đặc trưng khí hậu tương đồng. Nhóm đã thực hiện tối ưu hóa số cụm bằng phương pháp Elbow và hệ số Silhouette, đồng thời so sánh hiệu năng giữa phiên bản tự cài đặt và thư viện Scikit-learn.
- **Bài toán phân loại (Supervised Learning):** Xây dựng mô hình Softmax Regression và Logistic Regression để dự báo trạng thái nhiệt độ (Cold, Cool, Warm, Hot) tại thời điểm kế tiếp. Dữ liệu được làm giàu bằng các kỹ thuật mã hóa chu kỳ (Cyclical Encoding) và đặc trưng động để tăng độ chính xác.

Kết quả thực nghiệm cho thấy sự tương đồng cao giữa mô hình tự xây dựng và các thư viện chuẩn, khẳng định khả năng làm chủ lý thuyết và kỹ năng triển khai thực tế của nhóm trong bối cảnh dữ liệu IoT môi trường.

7.2 Ý nghĩa

Việc thực hiện đề tài "Phân tích và khai thác dữ liệu nhiệt độ theo thời gian cho các bài toán Machine Learning trong bối cảnh IoT" mang lại những giá trị quan trọng cả về mặt thực tiễn ứng dụng:

- **Tối ưu hóa năng lượng (Smart City):** Việc dự báo trạng thái nhiệt độ hỗ trợ các hệ thống điều hòa thông minh (HVAC) tự động điều chỉnh công suất trước khi nhiệt độ thay đổi, giúp tiết kiệm điện năng và tăng tuổi thọ thiết bị.
- **Ứng dụng trong Nông nghiệp thông minh:** Kết quả phân cụm giúp xác định các vùng có điều kiện khí hậu tương đương, hỗ trợ quy hoạch vùng canh tác và chuyển giao mô hình cây trồng phù hợp giữa các khu vực.
- **Cảnh báo sớm và An sinh xã hội:** Cung cấp công cụ dự báo ngắn hạn về các trạng thái thời tiết cực đoan, giúp người dân và các cơ quan quản lý có phương án ứng phó kịp thời với các biến động nhiệt độ đột ngột.

- **Kết luận về giá trị đạt được:** Đề tài không chỉ dừng lại ở mức độ bài tập kỹ thuật mà còn là tiền đề để phát triển các hệ thống giám sát môi trường diện rộng. Sự kết hợp giữa kỹ thuật IoT (thu thập dữ liệu) và Machine Learning (phân tích dữ liệu) chính là chìa khóa để xây dựng các giải pháp thông minh trong kỷ nguyên chuyển đổi số.

7.3 Hướng phát triển

7.3.1 Mở rộng dữ liệu

Trong phạm vi hiện tại, dữ liệu sử dụng cho cả hai bài toán phân loại và phân cụm vẫn còn tương đối hạn chế về quy mô và đa dạng. Do đó, một hướng phát triển quan trọng là mở rộng tập dữ liệu cả về số lượng lẫn phạm vi thu thập.

Đối với bài toán phân loại, việc bổ sung thêm dữ liệu từ nhiều khu vực địa lý khác nhau hoặc trong các điều kiện thời tiết đa dạng sẽ giúp mô hình học được các quy luật tổng quát hơn, từ đó cải thiện khả năng dự đoán trên dữ liệu thực tế. Ngoài ra, có thể xem xét bổ sung thêm các biến đầu vào như độ ẩm, tốc độ gió hoặc áp suất không khí để làm phong phú không gian đặc trưng.

Đối với bài toán phân cụm, việc mở rộng dữ liệu giúp các cấu trúc cụm trở nên rõ ràng và ổn định hơn. Khi số lượng mẫu tăng lên, các phương pháp phân cụm như K-means hoặc các phương pháp tự triển khai sẽ có điều kiện phát hiện chính xác hơn các nhóm tự nhiên trong dữ liệu, đồng thời giảm ảnh hưởng của nhiễu.

Bên cạnh đó, việc thu thập dữ liệu theo chuỗi thời gian dài hơn cũng là một hướng quan trọng, cho phép khai thác các xu hướng theo mùa hoặc theo chu kỳ, từ đó nâng cao chất lượng cả hai bài toán.

7.3.2 Cải tiến mô hình

Về mặt mô hình, mặc dù các phương pháp hiện tại đã đạt được kết quả tốt, vẫn còn nhiều hướng cải tiến có thể được xem xét.

Đối với bài toán phân loại, có thể thử nghiệm các mô hình nâng cao hơn như Gradient Boosting hoặc XGBoost nhằm khai thác tốt hơn các quan hệ phi tuyến trong dữ liệu. Ngoài ra, việc tối ưu siêu tham số (hyperparameter tuning) thông qua các phương pháp như Grid Search hoặc Random Search cũng có thể giúp cải thiện hiệu suất mô hình. Đối với mô hình tự triển khai, có thể bổ sung thêm các kỹ thuật như learning rate scheduling, regularization mạnh hơn hoặc cải tiến thuật toán tối ưu để tăng độ ổn định và tốc độ hội tụ.

Đối với bài toán phân cụm, có thể mở rộng sang các phương pháp phân cụm tiên tiến hơn như DBSCAN hoặc Gaussian Mixture Model nhằm xử lý tốt hơn các cụm có hình dạng phức tạp hoặc không đồng đều. Ngoài ra, việc lựa chọn số cụm tối ưu thông qua các tiêu chí như Silhouette Score hoặc Elbow Method cũng là một hướng cải tiến quan trọng.

Một hướng phát triển đáng chú ý khác là kết hợp giữa hai bài toán. Cụ thể, kết quả từ phân cụm có thể được sử dụng như một đặc trưng bổ sung cho bài toán phân loại, giúp mô hình tận dụng thêm thông tin về cấu trúc tiềm ẩn của dữ liệu. Ngược lại, kết quả phân loại cũng có thể hỗ trợ việc đánh giá chất lượng phân cụm.

7.3.3 Tổng kết hướng phát triển

Tổng thể, hướng phát triển của bài toán tập trung vào hai yếu tố chính: mở rộng dữ liệu và nâng cao mô hình. Trong đó, việc cải thiện chất lượng và đa dạng của dữ liệu được kỳ vọng sẽ mang lại tác động lớn nhất, trong khi các cải tiến về mô hình sẽ giúp khai thác tối đa thông tin từ dữ liệu. Đồng thời, việc kết hợp giữa phân loại và phân cụm mở ra tiềm năng xây dựng các hệ thống học máy linh hoạt và hiệu quả hơn trong thực tế.

Chương 8

Tài liệu tham khảo

Tài liệu tham khảo

[1] Giáo trình Học Máy, *Trường Đại Học Kinh Tế Kĩ Thuật Công Nghiệp*

[2] Scikit-learn Documentation, *Machine Learning in Python*, https://scikit-learn.org

[3] NumPy Documentation, *Fundamental package for scientific computing in Python*, https://numpy.org

[4] Pandas Documentation, *Data analysis and manipulation tool*, https://pandas.pydata.org

[5] Matplotlib Documentation, *Visualization with Python*, https://matplotlib.org

[6] GitHub, *Various machine learning implementations and examples*, https://github.com

[7] Kaggle, *Datasets and machine learning resources*, https://www.kaggle.com

[8] Google Developers, *Machine Learning Guides*, https://developers.google.com/machine-learning